

پردیس علوم دانشکده ریاضی، آمار و علوم کامپیوتر

آشنایی با هدوپ

نگارنده

آشنا گرگان محمدي

استاد: دکتر زهرا رضایی قهرودی

پروژه درس پردازش و مدلبن*دی* مهدادهها آبان ۱۴۰۰

چکیده

ما امروزه در دنیایی از مهداده ها زندگی میکنیم. لذا، ذخیره، پردازش و تحلیل این مهداده ها از اهمیت بالایی برخوردار است. یکی از محبوب ترین پلتفورم ها جهت ذخیره و پردازش مهداده ها، هدوپ است. هدوپ از زمان تولد تا کنون به یکی از بزرگترین اکوسیستم های تحلیل و پردازش مهداده ها بدل شده است؛ چنانکه بخش عمده ای از نرمافزارهای این حوزه را دربر می گیرد. در این گردایه، با هدوپ و تاریخچهٔ آن آشنا می شویم و نحوهٔ تعامل با آن را می آموزیم.

کلمات کلیدی: مهداده، هدوپ، اچدیافاس، یارن، پایتون

پیشگفتار

یکی از متداول ترین راه حلها جهت ذخیره و پردازش مهداده ها، به کارگیری از سیستمهای توزیعشده است. هدوپ بستری برای مدیریت و ذخیرهٔ داده ها بر روی یک خوشه از سیستمهای محاسباتی که بر روی یک شبکه قرار گرفته اند، فراهم می کند. همچنین، روشهایی جهت پردازش کارآمد داده ها و مدیریت وظایف و کارها ارائه می دهد. هدف این گردایه، آشنا کردن خواننده با مفاهیم اولیهٔ هدوپ و مبانی کار با آن می باشد. این گزارش به گونه ای تنظیم شده است تا نقشهٔ راهی برای شروع کار با هدوپ ارائه دهد و کتابچهٔ راهنمایی برای هر فردی که در ابتدای این راه است، فراهم آورد. در همین راستا، فصل اول به بیان مفاهیم و تاریخچهٔ هدوپ می پردازد. در این فصل، پس از بیان تعریف هدوپ و تاریخچهٔ پیدایش و گسترش آن، به تعریف دقیق تری از واحدهای اصلی آن پرداخته می شود. در انتها نیز برخی نرم افزارها و پروژه های مرتبط با اکوسیستم هدوپ را به صورت خلاصه معرفی می کنیم.

فصلهای بعد با هدف آموزش کار عملی با هدوپ تهیه و تنظیم شدهاند. در فصل دوم، ابتدا به چگونگی نصب و راهاندازی هدوپ پرداخته می شود. سپس، در فصل سوم، نحوهٔ کار با سیستم فایلهای توزیع شدهٔ هدوپ در خط فرمان و در برنامههای پایتون بررسی می شود. در نهایت، با بررسی مثالی عملی، نحوهٔ پردازش داده ها در هدوپ به کمک موتور مشهور نگاشت کاهش را در زبان پایتون نمایش می دهیم.

فصل پنجم نیز به جمع بندی مطالب و مرور مفاهیم و کارهای صورت گرفته می پردازد. همچنین، منابع بیشتری جهت مطالعهٔ دقیق تر به افراد علاقه مند پیشنها د می شود.

فهرست مطالب

١																												مفاه		١
١																					?	ت'	ئيس	چ	پ	هدو		١.١		
٣																								جه	خچ	تاري		۲.۱		
۶																						ر	،اسر	ف	ىاد	اچد;		٣.١		
٨																			ر	شر	ئاھ	تک	اشہ	ک	ِر ن	موتو		۴.۱		
٩																										يارن		۵.۱		
١١				•																•	پ	ىدو	م ھ	ىت	ىيى	اكوس		۶.۱		
14																			ب	ور	بدو	ه ر	زء	دا	ان	و راه	ب (نصر		۲
14																		پ	۔و	ها	ب	صد	ی ن	ناء	ے ھ	حالد		١.٢		
۱۵																					ها	دی	زمن	نيا	ب ز	نصر		۲.۲		
																										۲.۲				
16																					ز	ندو	ويا		۲.	۲.۲				
۱۷																						ب	.وپ	هد	ب د	نصب		٣. ٢		
۱۷								يط	ح	ے ہ	ناي	يره	تغ	م م	لي	تنغ	و ز	_ ر	وپ	ندو	a .	نلود	دا		١.	٣. ٢				
۲۱											٥	ئىد	بعش	زر	ەتو	شب	ن	لت	حا	ر .	، د	,	نص		۲.	٣. ٢				
74											ده	مش	زي	ٔتو	اماً	تم	ن	لت	حا	ر .	، د	,	نص		٣.	٣. ٢				
46																												۴. ۲		
٣.																			(س	1	ے اف	ردو	چ	با ا	کار	٥	نحو	•	٣
۳.											(مان	فره	٢	خه	.]	يے	Z	م ر	يق	طر	از	مل	عاه	، ت	نحو		١.٣		
46								ن	ىتو	، يا	بان	, ;	در		ىس	،نو	مه	, نا	, ب	ىة	ط	;1	مل	م اه	، ت	نحو		۲.۳		

۴	نگاشت کاهش در پایتون	41
	۱.۴ چگونگی نوشتن توابع نگاشت و کاهش	47
	۲.۴ بهرهگیری از کتابخانه ها	45
۵	جمع بندی و نتیجه گیری	۴٩
كتا	ابنامه	۵۱

فصل ۱

مفاهيم اوليه

در عصر مهداده ها، ذخیره و تحلیل حجم گستردهٔ داده ها که روزانه با سرعت و در تنوع بالا در حال تولید هستند، چالشی اساسی است. در راستای پاسخ به نیازهای امروز در حوزهٔ مهداده ها، بهرهگیری از ساختارهای توزیعی به عنوان یک راه حل عملی پیشنهاد می شود. سیستم های گوناگونی نیز در جهت پیاده سازی این راه حل توسعه یافته اند که هدوپ یکی از آن هاست. در این فصل، با هدوپ و تاریخ جه آن آشنا خواهیم شد و در ادامه، به بررسی مفاهیم اصلی و پروژه های اکوسیستم هدوپ می پردازیم.

۱.۱ هدوپ چیست؟

¹Hadoop

²Framework

³Open-source

⁴Clustering

⁵Node

⁶Data locality

- حفظ می شود، بلکه پردازشها به مراتب سریعتر صورت می گیرند [۱۱، ۶]. هدوپ شامل چهار واحد می باشد که عبارتند از:
- ۱. سیستم فایلهای توزیعشدهٔ هدوپ (اچدیافاس) V : یک سیستم فایلهای توزیعشده است که به سادگی بر روی سیستمهای استاندارد موجود در بازار قابل اجراست.
- ۲. نگاشت کاهش^۸: چارچوبی است که امکان انجام محاسبات به صورت موازی بر روی دادگان را فراهم می آورد.
- ۳. یک سیستم مدیریت منابع دیگر (یارن)^۹: این واحد، گرهها و استفادهٔ منابع در خوشه را
 پایش و مدیریت میکند و وظیفهٔ زمانبندی^{۱۱} کارها^{۱۱} و وظایف^{۱۲} را بر عهده دارد.
- ۴. واحد عام هدوپ^{۱۳}: این واحد شامل ابزارهای عامی به زبان جاوا است که در تمامی واحد قابل استفاده میباشند [۳، ۱۱، ۸].

هدوپ عمدتاً به زبان جاوا نوشته شده است و تنها بخشی از کدهای بومی آن به زبان سی و شِل میباشند. این امر موجب شده است که برنامههای جاوا سادهترین راه حل برای کار با هدوپ باشند. با این حال، رابطها^{۱۴} و کتابخانههایی^{۱۵} برای مدیریت اچدیافاس و نگارش نگاشتکاهش در زبانهای دیگر، از جمله پایتون، نیز فراهم شدهاند. همچنین، پروژههای دیگر در این اکوسیستم قابلیتهای بیشتری را در راستای سهولت برنامهنویسی به زبانهای دیگر فراهم کردهاند [۱].

معماری فیزیکی هدوپ به صورت ارباب_بردهای ۱۶ است؛ بدین معنا که گرههایی در خوشه (گرههای ارباب) مسئول مدیریت گرههای دیگر (گرههای برده) هستند. گرههای ارباب اساساً متشکل از گره نام 14 و نام ثانوی 14 و دنبالکنندهٔ کار 19 ، و گرههای برده شامل چندین گره

⁷Hadoop Distributed File System (HDFS)

⁸MapReduce

⁹Yet Another Resource Negotiator (YARN)

¹⁰Scheduling

¹¹Job

¹²Task

¹³Hadoop common

¹⁴Interface

¹⁵Library

¹⁶Master-slave

¹⁷Name node

¹⁸Secondary name node

¹⁹Job tracker

داده ۲۰ و دنبالکنندهٔ وظایف 1 است (شکل ۱.۱ (آ)) [۱۱، ۸]. از دیدگاه عملکر دی، می توان چهار لایه برای هدوب مفروض شد:

- 1. لایهٔ حافظهٔ توزیعشده: این لایه دربرگیرندهٔ اچدیافاس است. هر گره در یک خوشهٔ هدوپ منابع و پردازشهای مختص به خود را دارد. لذا، دادهٔ ورودی به بلوکهایی تقسیم میشود که به صورت توزیعشده و تکرارشونده ذخیره میشوند.
- ۲. لایهٔ مدیریت منابع خوشه: هدوپ باید بتواند هماهنگی خوبی میان گرههای خوشه ایجاد کند تا کاربرها و برنامهها بتوانند منابع را بهطور مؤثر به اشتراک بگذارند. بهطور سنتی، نگاشتکاهش مسئول مدیریت منابع و پردازش دادهها بود. با معرفی یارن، این دو عملکرد تفکیک شدند و یارن به عنوان یگانه ابزار مدیریت منابع خوشه شناخته شد.
- ۳. لایهٔ چارچوبهای پردازشی: این لایه دربرگیرندهٔ برخی چارجوبهای اکوسیستم هدوپ مانند اسپارک^{۲۲}، استورم^{۲۳} و بویژه موتور نگاشتکاهش است. این چارچوبها وظیفهٔ تحلیل و پردازش داده را برعهده دارند.
- ۴. لایهٔ رابط برنامه نویسی برنامه ۲۵: این لایه شامل ابزارها، برنامه ها و چارچوبهای دیگری است که نیازهای متنوعتری را برآورده میکنند. این ابزارها و برنامه ها پروژههایی هستند که در اکوسیستم هدوپ در حال توسعه میباشند (شکل ۱.۱ (ب)) [۵].

۲.۱ تاریخچه

داگ کاتینگ 77 ، خالق پروژهٔ لوسین 77 (یک کتابخانهٔ جستجوی متن)، به همراه مایک کافارللا 78 در صدد ایجاد یک موتور جستجوی وب 79 متنباز بودند. این پروژه که ناچ 79 نام داشت، در

²⁰Data node

²¹Task tracker

²²Spark

²³Storm

²⁴Tez

²⁵Application programming interface (API)

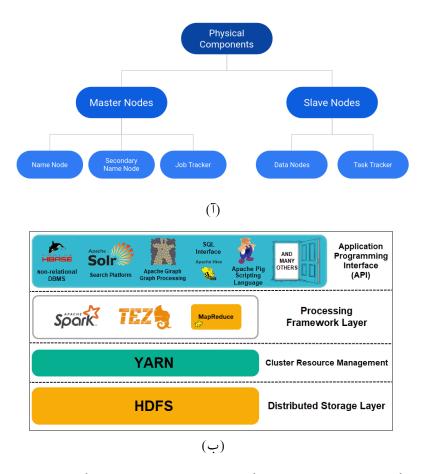
²⁶Doug Cutting

²⁷Lucene

²⁸Mike Cafarella

²⁹Web search engine

³⁰Nutch



شکل ۱.۱: $(\overline{1})$ معماری فیزیکی هدوپ. (ψ) معماری عملکردی هدوپ.

حقیقت بخشی از پروژه لوسین در بنیاد نرمافزاری آپاچی بود. کاتینگ و کافارلا میدانستند که ساخت و پیادهسازی یک موتور جستجو از پایه بسیار هزینهبر است. با این حال، این ریسک را پذیرفته و در سال ۲۰۰۲، این پروژه را کلید زدند و سیستم جستجو و خزشگر وب خود را توسعه دادند. از اولین چالشهایی که در مقابل آن دو قرار گرفت، حجم زیاد صفحات وب بود. در همین زمان و در سال ۲۰۰۳، گوگل معماری خود در حل این چالش، تحت عنوان سیستم فایلهای توزیعشدهٔ گوگل را طی مقالهای معرفی کرد. خیلی زود معماری مشابهی در ناچ تحت عنوان سیستم فایلهای توزیعشدهٔ ناچ ارائه شد و در سال ۲۰۰۴ به صورت متن باز پیادهسازی شد. در همین سال، گوگل مقالهٔ دیگری منتشر کرد که در آن موتور نگاشت کاهش را به جهانیان معرفی می کرد. با افزودن موتور نگاشت کاهش را به جهانیان معرفی می کرد. با

توسعه دهندگان بر این باور بودند که سیستم فایلهای توزیعشدهٔ ناچ و پیاده سازی آنها از نگاشت کاهش محدود به حوزهٔ جستجو نیست. لذا در سال ۲۰۰۶، از ناچ به سمت یک زیرپروژهٔ دیگری از لوسین تحت عنوان هدوپ مهاجرت کردند و اولین نسخهٔ هدوپ منتشر شد. ملحق شدن کاتینگ به یاهو ۳ در همین سال نیز موجب شد تا بستر مناسبی جهت توسعهٔ هدوپ به عنوان یک سیستم قابل اجرا در مقیاس وب فراهم شود. بدین ترتیب، یاهو به یکی از اولین استفاده کنندگان هدوپ بدل شد. هدوپ در سال ۲۰۰۸ به یک پروژهٔ مستقل در بنیاد نرمافزاری آپاچی تبدیل شد که مسیر موفقیت آن را هموارتر کرد و موجب شد تا از اجتماعی متنوع و فعال برخوردار شود. در این سال، علاوه بر یاهو، شرکتهایی نظیر فیس بوک۳٬ است داتاف ام۳۰ و نیویورک تایمز ۳۰ این تکنولوژی بهره می بردند.

هدوپ نام خود را وامدار فرزند کاتینگ است! در زمانی که کاتینگ به دنبال نامی برای پروژه بود، فرزند او در حال بازی با عروسک فیل زرد خود به نام هدوپ بود. کاتینگ در این رابطه می گوید:

[هدوپ] نامی کوتاه، بهراحتی قابل تلفظ و بیمعنی بود که هیچ جای دیگر بهکار نرفته بود. این موارد معیارهای من در نامگذاری هستند. کودکان در تولید چنین نامهایی تبحر دارند.

و اینگونه شد که هدوپ با نماد فیل زرد برای این پروژه انتخاب شد.

همانطور که پیشتر اشاره شد، نسخهٔ اولیهٔ هدوپ در سال ۲۰۰۶ منتشر شد. این پروژه در سال ۲۰۱۱ به طور رسمی به صورت متن باز در دسترس قرار گرفت. در این سالها، نسخههای اصلاحی دیگری از پروژه نیز منتشر شد که تغییراتی جزئی نسبت به نسخه اولیه داشتند. بعد از حدود ۸ سال، در سال ۲۰۱۲ نسخهٔ دوم با بهرهگیری از یارن، که در سال ۲۰۱۲ معرفی شده بود، ارائه شد [۱۱]. اصلاحات متعددی بر روی این نسخه نیز صورت گرفت تا نهایتاً در سال ۲۰۲۰ نسخهٔ سوم آن با پشتیبانی از نسخهٔ هشتم جاوا منتشر شد (توسعهٔ نسخه هفتم جاوا در سال ۲۰۱۵ متوقف شد). نسخهٔ سوم بهبودهایی در راستای مقاومت در برابر خرابیهای سیستم و کاهش سربار حافظه اعمال کرده است. همچنین، امکان بهرهگیری از کارت گرافیک را در خوشهها فراهم آورده است [۲،۴].

³¹ Yahoo!

³²Facebook

³³Last.fm

³⁴New York Times

۳.۱ اچدیافاس

همانطور که پیشتر اشاره شد، اچدیافاس یا همان سیستم فایلهای توزیعشدهٔ هدوپ، به منظور ذخیرهٔ دادگان حجیم به صورت توزیعشده بر روی سیستمهای موجود در یک خوشهٔ هدوپ و با الگوی دسترسی به صورت جریانی از داده ها به کار می رود. در این تعریف، منظور از الگوی دسترسی به صورت جریانی از داده ها آن است که منطق طراحی اچدیافاس بر پایهٔ الگوی «یک بار نوشتن و چندین بار خواندن» است. به عبارت دیگر، اچدیافاس به منظور انجام به روزرسانی های متعدد بر روی داده ها ساخته نشده است، بلکه در راستای تحلیل گسترده و چندیاره به وجود آمده است.

اچدی اف اس به گونه ای طراحی شده است که از قابلیت تحمل خطا^{۳۵} و دسترس پذیری 77 بالایی برخوردار است. در این طراحی، داده به بلوکهای بزرگی (معمولاً ۱۲۸ یا ۲۵۶ مگابایت) تقسیم شده و کپیهای مجزایی از آن (سه نسخه به صورت پیش فرض) در گرههای متنوع در رکهای 77 متعدد ذخیره می شوند (منظور از رک، مجموعه ای فیزیکی از چندین گره در خوشه است). بدین ترتیب، اگر یکی از گرهها و یا حتی یک رک دچار اختلال شود، تأثیر آن در کل سیستم قابل چشم پوشی است و عملیات پردازش داده ها بدون هیچ مشکلی ادامه می یابد. الگوریتم تکرار بلوک داده در گرههای رکهای مختلف که به الگوریتم رک آگاه 77 معروف است، بدین صورت عمل می کند که تکرار اول را در همان رک کارخواه 79 قرار می دهد. سپس، یک رک دیگر به صورت تصادفی انتخاب شده، و دو تکرار روی گرههای مجزا در آن رک قرار می گیرند. در جهت جایدهی تکرارهای دیگر از بلوک داده در خوشه، گرههای مجزا به صورت تصادفی از مجموعهٔ تمام گرههای مجزو در خوشه (بدون توجه به رک) انتخاب شده و عملیات ذخیره سازی انجام می شود.

اچدیافاس شامل گره نام، گره نام ثانوی و چندین گره داده است. پس از شکستن داده به تعدادی بلوک، این بلوکها به کمک گرههای داده در سرورهای برده ذخیره می شوند. ابردادههای ۴۰ این بلوکها، شامل نام فایل، مجوزهای فایل، شناسهها، مکان ذخیره و تعداد تکرارها ۴۱، در حافظهٔ داخلی گره نام ذخیره می شوند (شکل ۲.۱). آنچه از این توضیحات برمی آید آن است که اگر گره نام دچار اختلال شود، اچدی اف اس دیگر قادر نخواهد بود تا دادگان را بر روی گرههای داده توزیع کند. بنابراین، اختلال در گره نام موجب اختلال در کل خوشه می شود. برای حل این مشکل، از

³⁵Fault-tolerance

³⁶Availability

³⁷Rack

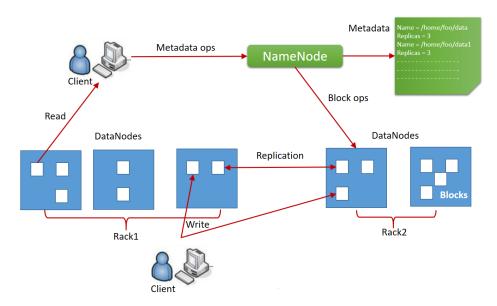
³⁸Rack-aware algorithm

³⁹Client

⁴⁰Metadata

⁴¹Replica

گره نام ثانوی بهره گرفته میشود. در نسخههای اولیهٔ هدوپ، گره نام ثانوی نسخهٔ پشتیبان^{۴۲} اولیه از گره نام بود. گره نام ثانوی بهطور معمول یک کپی از ابردادههای فعلی و پیشینهٔ ویرایشهای^{۴۲} صورتگرفته از گره نام تهیه و آنها را ادغام میکند.



شكل ۲.۱: شماى كلى سيستم فايلهاى توزيعشدهٔ هدوپ.

فرآیند رفع مشکل در صورت بروز اختلال در گره نام به کمک پشتیبان موجود در گره نام ثانوی، نیازمند دخالت سرپرست سیستم است. در راستای اتوماسیون فرآیند بازیابی حالت عادی پس از ایجاد اختلال در گره نام، در نسخهٔ دوم هدوپ جفتی از گرههای نام با وضعیتهای فعال آمادهبهکار ۴۴ لحاظ شدهاند. بدین ترتیب، در صورت بروز مشکل در گره نام فعال، گره نام آمادهبهکار وظایف را از سر میگیرد و وضعیت آن به فعال تغییر میکند. لازم به ذکر است که در راستای افزایش دسترس پذیری، دو گره نام از یک حافظهٔ اشتراکی با دسترس پذیری بالا برای ذخیرهٔ پیشینهٔ ویرایشها بهره می برند تا تغییر گره نام فعال در کمترین زمان ممکن رخ دهد (برای اطلاعات بیشتر در خصوص چگونگی انتخاب این حافظهٔ اشتراکی به کلمات کلیدی NFS filer و Quorum این حافظهٔ اشتراکی به کلمات کلیدی journal manager

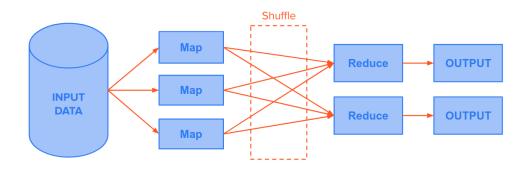
⁴²Backup

⁴³Edit logs

⁴⁴Active-standby

۴.۱ موتور نگاشت کاهش

همانطور که پیشتر اشاره شد، موتور نگاشتکاهش اولین بار در مقالهای توسط گوگل مطرح شد. موتور نگاشتکاهش بهمنظور پردازش سریع و موازی دادههای توزیعشده در یک خوشه بهکار میرود و کارهای مرتبط با پردازش داده را به دو فاز نگاشت و کاهش تقسیم میکند. در حالت کلی، میتوان گفت که تابع نگاشت عمدتاً به آمادهسازی داده پرداخته، نتایجی به صورت زوجهای کلید_مقدار 49 تولید میکند که پس از درهمآمیزی 49 و مرتبسازی، به عنوان ورودی به تابع کاهش، که محاسبات و تجمیع نتایج بر روی دادهها را انجام میدهد، داده میشوند. شکل 80 شمای کلی موتور نگاشتکاهش را نشان میدهد.



شكل ۳.۱: شماى كلى موتور نگاشتكاهش.

هر کار نگاشتکاهش، یک واحد از عملیات مورد نظرِ کارخواه است و متشکل از دادههای ورودی، برنامهٔ نگاشتکاهش و اطلاعات پیکربندی میباشد. در هدوپ، این کارها به دو وظیفهٔ نگاشت و کاهش تقسیم میشوند. وظایف به کمک یارن (که در بخش بعد بیشتر به آن خواهیم پرداخت) زمان بندی و بر روی گرههای خوشه اجرا میشوند. در صورت بروز هرگونه مشکل در یکی از این وظایف، عملیات مجدد زمان بندی میشود تا بر روی گره دیگری اجرا شود. علاوه براین، هدوپ دادهٔ ورودی را به قطعههای با طول برابر تقسیم میکند. سپس، هدوپ یک وظیفهٔ نگاشت به ازای هر قطعه ایجاد میکند که در حقیقت، تابع نگاشتی که کاربر تعریف کرده است را بر روی رکوردهای آن قطعه اجرا میکند. هدوپ تلاش میکند تا انجام وظیفهٔ نگاشت را به گرهای محول کند که داده در آن ذخیره شده است. با این حال، در شرایطی ممکن است آن گره در حال انجام وظیفهٔ دیگری باشد. در این صورت، ابتدا سعی میکند گرهای بیکار در همان رک بیابد و اگر موفق وظیفهٔ دیگری باشد. در این صورت، ابتدا سعی میکند گرهای بیکار در همان رک بیابد و اگر موفق

⁴⁵ Key-value

⁴⁶Shuffle

نشود، از گرهای خارج از رک استفاده خواهد کرد. با توجه به آنچه گفته شد، اندازهٔ بهینه برای قطعات ورودی به اندازهٔ سایز بلوکهای اچدیافاس است؛ زیرا در این صورت، تضمین می شود که هر وظیفهٔ نگاشت قابل اجرا بر روی یک گره داده خواهد بود و در صورت اختلال در یک گره داده، عملیات نگاشت بر روی دیگر گرهها بدون مشکل و به صورت مستقل قابل انجام خواهد بود. تابع نگاشت به ازای اجرا بر روی قطعات ورودی، زوجهایی به صورت کلید مقدار تولید می کند.

تابع نکاشت به ازای اجرا بر روی قطعات ورودی، زوجهایی به صورت کلید مقدار تولید می کند. این زوجها داده هایی میانی هستند که در ادامه به عنوان ورودی به تابع (های) کاهش داده خواهند شد و استفادهٔ دیگری ندارند. لذا، این زوجها بر روی اچدی اف اس ذخیره نمی شوند و تنها بر روی حافظهٔ داخلی نوشته می شوند. پیش از آن که این زوجها به تابع کاهش وارد شوند، درهم آمیخته شده و با توجه به کلید مرتب می شوند. در نهایت، تابع کاهش زوجها را به ترتیب خوانده و پس از تجمیع و پردازش، خروجی را برای ذخیره بر روی اچدی اف اس تولید می کند. در صورت وجود حجم بالای دادگان، اگر تجمیع و پردازش مورد نظر قابل شکستن باشد، یک تابع تلفیق گر ۴۷ نیز تعریف می شود. تابع تلفیق گر ۴۷ نیز بر روی خروجی های هر تابع نگاشت اجرا می شود و بار محاسباتی در هم آمیختن و مرتبسازی خروجی های تابع نگاشت را کاهش می دهد.

برای مثال، فرض کنید دادههای مربوط به دسترسی افراد به یک وبسایت در اختیار است و میخواهیم تعداد درخواست برای دسترسی هر فایل را محاسبه کنیم. بدین منظور، تابع نگاشتی نوشته ایم که بهازای هر وقوع نام یک فایل در قطعهٔ ورودی، نام فایل را به همراه عدد ۱ در خروجی می نویسد. بدون نوشتن تابع تلفیقگر، لازم است تمامی این زوجهای (نام فایل،۱) به ترتیب نام فایل مرتب شوند و سپس به کمک تابع کاهش و با تجمیع ۱ها، تعداد کل درخواستها برای آن فایل محاسبه شود. در راستای کاهش محاسبات جهت مرتبسازی خروجیهای تابع نگاشت، می توان یک تابع تلفیقگر نوشت که خروجی هر قطعه پس از نگاشت را مرتب و تعداد وقوع هر نام فایل را بشمارد و در خروجی بنویسد و سپس، خروجی آن مرتب و با تابع مشابهی، عملیات کاهش صورت گیرد. کد مربوط به این مثال را به صورت صریح در بخشهای آینده مشاهده خواهیم کرد [۱۱، ۹، ۶].

۵۰۱ يارن

در نسخهٔ اول هدوپ، موتور نگاشت کاهش به تنهایی بار پردازش داده و مدیریت منابع را به دوش می کشید. به مرور زمان، اهمیت تفکیک این دو عملیات پررنگ شد و به توسعهٔ یارن ختم شد. یارن ابزار مدیریت خوشهٔ پیش فرض در نسخه های دوم و سوم هدوپ است که امکان تعریف رابطها

⁴⁷Combiner

جهت پیادهسازی موتور پردازشی سفارشیسازی شده را نیز میدهد. یارن شامل دو دیمن^{۴۸} است: یک مدیر منابع که مصرف منابع در خوشه را مدیریت میکند و تعدادی مدیر گره که روی هر گره درون خوشه قرار دارند و کانتینرها^{۴۹} را پایش و آغاز میکنند. هر کانتینر یک فرآیند مختص برنامه را با توجه به محموعهای از محدودیتها در منابع، اجرا میکند.

بهمنظور اجرای یک برنامه بر روی یارن، کارخواه یک درخواست به مدیر منابع ارسال میکند. مدیر منابع فرمانی به مدیر گره جهت آغاز یک اربابِ برنامه ۵۰ صادر میکند که در یک کانتینر قرار میگیرد. سپس، ارباب برنامه خود را به مدیر منابع معرفی میکند تا اجازهٔ ارتباط با گره (های) نام، یافتن محل ذخیرهٔ بلوکهای داده و انجام محاسبات لازم در وظایف نگاشت و کاهش برای پردازش داده را اخذ کند. پس از آن، ارباب برنامه منابع مورد نیاز را از مدیر منابع درخواست میکند و به تعامل با منابع مورد نیاز در طول چرخهٔ حیات کانتینر، ادامه میدهد. مدیر منابع نیز به زمان بندی منابع درخواستی ارباب برنامه میپردازد و صفی از درخواستها تشکیل میدهد. با آزاد شدن منابع، آنها را در اختیار ارباب برنامه جهت تخصیص به گره بردهٔ مشخص، قرار میدهد. ارباب برنامه درخواستی به مدیر آن گره برده ارسال میکند تا یک کانتینر حاوی متغیرها، توکنهای احراز هویت و رشتهٔ دستورات فرآیند مورد نظر ایجاد کند. در تمام لحظات، ارباب برنامه بر اجرای فرآیندها رباب برنامه نتایج را به برنامهٔ کارخواه ارسال میکند و پس از اعلام سیگنال خاتمه به مدیر منابع، ارباب برنامه نتایج را به برنامهٔ کارخواه ارسال میکند و پس از اعلام سیگنال خاتمه به مدیر منابع، اجرای خود را نیز متوقف میکند [۱، ۱، ۵].

زمانبندی بر روی یک خوشه از اهمیت بالایی برخوردار است. سه زمانبندی که یارن از آنها بهره می برند، عبارتند از:

- ۱. فیفو^{۵۱}: این زمانبند برنامهها را در یک صف قرار می دهد و به ترتیب ارسال، آنها را اجرا می کند؛ بدین نحو که ابتدا منابع به درخواستهای برنامهٔ اول در صف اختصاص می یابند و پس از پایان انجام وظایف مربوط به درخواستها، منابع در اختیار برنامهٔ بعدی در صف قرار می گیرند.
- ۲. زمان بند ظرفیت^{۵۲}: در این زمان بند، یک صف اختصاصی مجزا وجود دارد که امکان اجرای کارهای کوچک را به محض ارسال فراهم میکند. بهرهوری این زمان بند نسبت به زمان بند

⁴⁸Daemon

⁴⁹Container

⁵⁰Application master

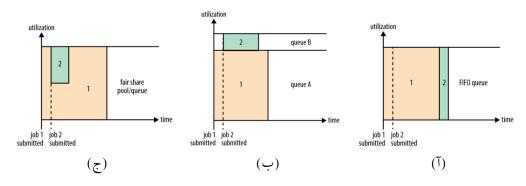
⁵¹FIFO (First in, first out)

⁵² Capacity Scheduler

فیفو کمتر است؛ چراکه بخشی از ظرفیت صف برنامه ها برای کارهای این صف اختصاصی محفوظ می ماند و برنامه های بزرگ به طور معمول دیرتر از حالتی که از زمان بند فیفو استفاده شده باشد، خاتمه می یابند.

۳. زمانبند منصفانه^{۵۳}: در این زمانبند، منابع به صورت پویا به کارهای در حال اجرا تخصیص مییابند و ظرفیت محفوظی وجود ندارد [۱۱].

شکل ۴.۱ تفاوت بین این سه زمانبند را بهخوبی نشان میدهد.



شكل ۴.۱: (آ) زمان بند فيفو. (ب) زمان بند ظرفيت. (ج) زمان بند منصفانه.

۶.۱ کوسیستم هدوپ

هدوپ به این واحدهای اصلی محدود نمی شود، بلکه بسیاری دیگر از پروژهها و برنامههای وابسته را نیز شامل می شود. در این بخش به بررسی اجمالی برنامههای موجود در اکوسیستم هدوپ می پردازیم. کاساندرا ۴۰ یک پایگاه دادهٔ متن باز و توزیع شده با مدل ذخیرهٔ ستونی نواس کیوال 40 است. این پایگاه داده نقطهٔ شکست واحد ندارد، گسترش پذیر است و زبان پرس وجوی 40 اختصاصی و مشابه با زبان اس کیوال را دارد.

اچبیس: اچبیس ۵۷ یک پایگاه دادهٔ توزیعشدهٔ ستون محور است که بر روی اچدی اف اس ساخته

⁵³Fair scheduler

⁵⁴Cassandra

⁵⁵NoSQL

⁵⁶Query

⁵⁷HBase

شده است. اچبیس برنامهای در اکوسیستم هدوپ است که جهت رفع نیاز خواندن و نوشتن بلادرنگ در مجموعهٔ دادگان خیلی بزرگ توسعه یافته است.

اوزون: اوزون^{۵۸} یک پایگاه توزیعشده برای ذخیرهٔ اشیاء به صورت کلید_مقدار است که می تواند فایل های بزرگ و کوچک را به طور مشابه و کارا مدیریت کند. اوزون برنامه ای است که اخیراً معرفی شده است و همچنان در حال توسعه است. این برنامه می تواند به راحتی در کنار دیگر برنامه های اکوسیستم هدوپ، از جمله اسپارک، کار کند.

آورو: آورو^{۵۹} یک سیستم مسلسلسازی^{۰۰} داده است. آورو از جیسون^{۲۱} برای تعریف انواع داده و پروتکلهای داده بهره میبرد و داده را بهصورت فشرده و دودویی مسلسلسازی میکند.

زوکیپر: زوکیپر^{۶۲} سرویس هماهنگسازی سیستمهای توزیعشده در هدوپ است. زوکیپر بستری برای ذخیرهٔ سلسلهمراتبی کلید_مقدارها ارائه میکند که بهمنظور فراهم آوردن پیکربندی و همزمانی به صورت توزیعشده توسعه یافته است.

هایو: هایو⁹⁷ یک پروژهٔ نرمافزاری انبار داده، توسعه یافته توسط فیسبوک است که امکان تحلیل و پرسوجو را در هدوپ فراهم میکند. هایو نیز یک رابط زبانی مشابه اسکیوال جهت انجام پرسوجوها ارائه میکند.

پیگ: پیگ^{۶۴} با افزودن یک انتزاع به موتور نگاشتکاهش، موجب تسهیل پردازش دادهها میشود و برنامهنویسی سطح بالا برای نگارش موتور نگاشتکاهش فراهم میکند.

اسپارک: اسپارک⁶⁰ یکی از معروفترین موتورهای تحلیل داده در پردازش دادههای حجیم است که توسط دانشگاه برکلی توسعه یافته است. اسپارک یک رابط به منظور برنامه نویسی کل خوشه با موازی سازی و تحمل خطای صریح را در اختیار قرار می دهد. این موتور سریع متن باز امکان پرس وجو، پردازش دسته ای، تحلیل جریان داده ها، پیاده سازی و اجرای الگوریتم های یادگیری ماشین و نیز تعریف پایگاه داده های گراف را فراهم می کند. اسپارک از موتور

⁵⁸Ozone

⁵⁹Avro

⁶⁰Serialization

⁶¹ JSON

⁶²ZooKeeper

⁶³Hive

⁶⁴Pig

⁶⁵https://spark.apache.org/

نگاشتکاهش استفاده نمیکند و به توانایی آن در نگه داشتن مجموعهٔ دادگان در حافظه بین کارها شهرت دارد.

استورم: استورم ^{۶۶} یک چارچوب محاسباتی برای پردازش جریان داده های توزیع شده است. ساختار آن به صورت گراف جهت دار بدون دور است و عمدتاً به زبان کلوژر ^{۶۷} نوشته شده است.

تز: تز⁶ نیز یک چارچوب پردازشی با ساختار گراف جهتدار بدون دور است. تز چارچوبی مبتنی بر یارن است که بهمنظور توسعهٔ برنامههای پردازش داده بهصورت دستهای و تعاملی و طراحی نحوهٔ جریان داده پدید آمده است.

ماهوت: ماهوت ^{۶۹} یک پروژه جهت فراهم آوردن پیادهسازیهایی توزیعشده و گسترش پذیر از الگوریتمهای یادگیری ماشین و بر پایهٔ جبر خطی است. ماهوت پیش تر بر پایهٔ پلتفورم هدوب نوشته شده بود ولی نسخههای جدید آن بر اسپارک تمرکز دارند.

ساب مارین: ساب مارین ۷۰ یک پلتفورم هوش مصنوعی است که امکان اجرای الگوریتمهای یادگیری ماشین و یادگیری عمیق را در خوشههای توزیعشده فراهم میکند.

امباری: امباری ۷۱ یک ابزار مبتنی بر وب است که جهت پایش و مدیریت خوشههای هدوپ و برنامههای مرتبط توسعه یافته است. امباری یک داشبورد مدیریتی را در اختیار کاربر قرار میدهد که به کمک آن می توان سلامت خوشهها را بررسی کرد.

حال که با مفاهیم اولیه و برخی پروژههای مرتبط با هدوپ و اهداف آنها آشنا شده ایم، می توانیم در راستای یادگیری نحوهٔ کار با هدوپ گام برداریم. لذا در ادامه، به بررسی نحوهٔ نصب و راهاندازی هدوپ پرداخته و سپس، کار با اچدی اف اس و نگارش موتور نگاشت کاهش، در کنار چالشهای موجود را به صورت عملی و در بستر خط فرمان و برنامه های به زبان پایتون مورد مطالعه قرار می دهیم.

⁶⁶http://storm.apache.org/

⁶⁷Clojure

⁶⁸https://tez.apache.org/

⁶⁹Mahout

⁷⁰Submarine

⁷¹Ambari

فصل ۲

نصب و راهاندازی هدوپ

۱۰۲ حالتهای نصب هدوپ

هدوپ در سه حالت قابل نصب است:

- ۱. حالت مستقل ا: با وجود اینکه هدوپ یک پلتفورم توزیعشده است، می توان آن را بر روی یک گره و به صورت مستقل نیز نصب کرد. در این حالت، هدوپ مانند یک سیستم که بر روی محیط جاوا اجرا می شود، عمل می کند. حالت مستقل عمدتاً به هدف عیبیابی از برنامه های هدوپ مورد استفاده قرار می گیرد؛ به طور مثال، می توانیم صحت برنامه های نگاشت کاهش را پیش از اجرای آن ها در یک خوشه مورد بررسی قرار دهیم.
- حال شبه توزیع شده ۱: در این حالت نیز نصب بر روی یک گره صورت می گیرد؛ با این تفاوت
 که یک شبیه سازی از یک خوشهٔ هدوب بر روی آن گره در اختیار خواهد بود. بنابراین،
 دیمن های مختلف، از جمله گره نام، گرههای داده، دنبال کنندهٔ وظیفه و دنبال کنندهٔ کار،
 همگی بر روی یک ماشین جاوا اجرا می شوند.
- ۳. حال تماماً توزیعشده ۳: در این حالت، تعدادی گره در اختیار است که یک خوشهٔ هدوپ را تشکیل میدهند. در این تنظیمات، گره نام، گره نام ثانوی و دنبالکنندههای کار بر روی

¹Standalone mode

²Pseudo-distributed mode

³Fully-distributed mode

گره ارباب عمل تنظیم میشوند و گرههای داده و دنبالکنندهٔ وظایف بر روی گرههای برده قرار میگیرند [۱۱].

در این فصل نحوهٔ نصب آخرین نسخهٔ هدوپ در هر سه حالت را بر روی سیستمهای مبتنی بر لینوکس_دبیان و ویندوز شرح می دهیم. توجه کنید که با توجه به محدودیتهای موجود، تنها نصب بر روی سیستم لینوکس آزمایش شده است و نصب حالت تماماً توزیع شده نیز تست نشده است. با این حال، با بررسی منابع مختلف و صحت سنجی مراحل گفته شده با توجه به زیر ساختهای لازم، مطالب به منظور نصب و راه اندازی هدوپ بر روی سیستم های مبتنی بر ویندوز و نیز نصب در حالت تماماً توزیع شده، به صورت تئوری تشریح شده اند. مباحث بر پایهٔ منابع [11], [11] و [11] و با توجه به تجربهٔ عملی تنظیم شده اند.

۲.۲ نصب نیازمندیها

۱.۲.۲ لينوكس_دبيان

پیش از هر چیز، لازم است نرمافزارهای سیستم را بهروز کنیم. بنابراین، ابتدا دستورات زیر را در ترمینال (خط فرمان) اجرا می کنیم:

```
$ sudo apt update
$ sudo apt upgrade
```

همانطور که در فصل اول اشاره شد، عمدهٔ پروژه هدوپ به زبان جاوا نوشته شده است و سرویسهای آن نیازمند محیط زمان اجرای جاوا (جِیآرای) و کیت توسعهٔ جاوا (جِیدی کِی) است. پکیج اُپنجی دی کی 3 در سیستمهای مبتنی بر دبیان لینوکس از جمله اوبونتو هر دو نیازمندی را دربردارد. نسخهٔ سوم هدوپ از نسخهٔ هشتم جاوا پشتیبانی می کند و لذا کافیست دستورات زیر را اجرا کنیم:

```
$ sudo apt install openjdk-8-jdk -y
```

پس از پایان یافتن نصب، برای اطمینان از نصب صحیح، میتوانید نسخهٔ جاوا و کامپایلر آن را به کمک دستورات زیر بررسی کنید:

⁴Java runtime environment

⁵Java development kit

⁶OpenJDK

به منظور اطمینان از عملکرد امن هدوپ، لازم است یک اتصال اس اس ا $^{\vee}$ بدون نیاز به پسورد به میزبان محلی $^{\wedge}$ برقرار کنیم. به منظور نصب نسخه های مرتبط با میزبان و کارخواه اس اس ا $^{\vee}$ ، از دستور زیر استفاده میکنیم:

```
$ sudo apt install openssh-server openssh-client -y
```

توصیه می شود که یک کاربر بدون دسترسی روت ایجاد شود تا از اشتباهاتی که منجر به تغییر تنظیمات اصلی سیستم می شود، جلوگیری شود. دستورات زیر، یک کاربر با نام bigdata و بدون دسترسی روت ایجاد کرده، به محیط آن کاربر وارد شده، و تنظیمات اساس اچ را برای اتصال این کاربر به میزبان محلی انجام می دهد:

```
$ sudo adduser bigdata
$ su - bigdata
$ ssh-keygen -t rsa -P '' -f ~/.ssh/id_rsa
$ cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
$ chmod 0600 ~/.ssh/authorized_keys
$ ssh localhost
```

۲.۲.۲ ویندوز

برای نصب در ویندوز، همچنان نصب نسخهٔ هشتم جاوا نیاز است. با این حال، جهت فراهم کردن فضای خط فرمان مناسب، ابتدا باید دو نرم افزار پاورشل و یکی از گیتبَش ٔ یا سونزیپ ٔ فضای خط فرمان مناسب، ابتدا باید دو نرم افزار پاورشل و یکی از گیتبَش ٔ یا سونزیپ ٔ فضای خط فرمان مناسب، ابتدا باید دو نرم افزار پاورشل و یکی از گیت بسون نیس با بیدا باید دو نرم افزار پاورشل و یکی از گیت بسون نیس با بیدا باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیت بسون نیس باید دو نرم افزار پاورشل و یکی از گیر باید دو نرم افزار پاورشل و یکی از گیر باید دو نرم بای

⁷SSH (Secure shell)

⁸Localhost

⁹PowerShell

¹⁰Git Bash

¹¹⁷ Zip

نصب شوند. با توجه به معماری سیستم خود، میتوانید فایل زیپ جهت نصب پاورشل را از طریق یکی از لینکهای زیر دریافت کنید.

- معماری ۶۴ بیتی
- معماری ۳۲ بیتی
- معماری اِیآرام۲۲ ۶۴ بیتی
 - معماری اِیآرام ۳۲ بیتی

به علاوه، می توانید در خط فرمان سی ام دی ۱۳ دستور زیر را اجرا کنید:

winget search Microsoft.PowerShell

سونزیپ یا گیتبش در فرآیند نصب تنها جهت خارج کردن فایلهای دودویی هدوپ از حالت فشرده استفاده خواهند شد. با این حال، از آنجایی که گیتبش بستر مناسبی برای کار با گیت را نیز فراهم میکند، نصب آن توصیه میشود. برای نصب این دو نرمافزار نیز میتوانید از مسیرهای زیر اقدام کنید:

- لینک کمکی برای نصب سونزیپ (با توجه به معماری سیستم خود، فایل exe مناسب را دانلود کنید)
 - لینک نصب گیتبش

برای نصب جاوا، پس از دانلود فایل متناسب با معماری سیستم خود از سایت اُراکِل ۱۴، فایل exe دانلود شده را اجرا کرده و به کمک راهنمای تصویری فراهم شده در این سایت، بهراحتی آن را نصب کنید.

۳.۲ نصب هدوپ

۱.۳.۲ دانلود هدوپ و تنظیم متغیرهای محیط

برای نصب هدوپ، ابتدا به سایت رسمی پروژه آپاچی هدوپ رفته و با انتخاب گزینهٔ binary در مقابل نسخهٔ مورد نظر (شکل ۱.۲ (آ))، روی لینکی که جهت دانلود به شما پیشنهاد می شود

¹²ARM

¹³cmd

¹⁴Oracle

(شکل ۱.۲ (ب)) کلیک کنید و یا آن را کپی کنید تا از طریق خط فرمان و به کمک دستورات زیر فایل را دانلود کنید (اگر بر روی سیستم لینوکس کار میکنید، ابتدا مطمئن شوید که به عنوان کاربری که در بالا ایجاد کردهاید، وارد شوید.):

```
# Ubuntu/Debian
$ wget <mirror-link>
# Windows (PowerShell)
$ client = new-object System.Net.WebClient
$ client.DownloadFile(<mirror-link>, path/to/save/file)
```

پس از اتمام، به محلی که فایل دانلود شده (که یک فایل فشرده با فرمت است) در آن ذخیره شده است رفته و آن را از حالت فشرده خارج نمایید:

```
# Ubuntu/Debian, Windows (Git Bash)
$ cd path/to/file
$ tar xzf file.tar.gz
```

برای نصب هدوپ بر روی ویندوز، لازم است فایلهای مربوط به ورودی/خروجی بومی هدوپ^{۱۵} نیز نصب شوند. فایلهای مورد نیاز بهتفکیک نسخهٔ هدوپ در این ریپازیتوری گیتهاب قرار گرفتهاند و با انتخاب نسخهٔ مورد نظر، تمام فایلها جهت دانلود به شما نمایش داده می شوند. فایلها را دانلود کرده و در فولدر bin در محل نصب هدوپ قرار دهید.

توجه! تا این لحظه، تنها فایلهای ورودی/خروجی بومی هدوپ تا نسخهٔ ۳.۲.۲ در گیتهاب قرار داده شدهاند. لذا هنگام انتخاب نسخهٔ هدوپ جهت نصب بر روی ویندوز، این نکته را در نظر داشته باشید.

مراحل بالا در صورتی که دقیق مطابق با دستورالعملها انجام شوند، بدون خطا خواهند بود و آمادهٔ تعریف تنظیمات لازم برای نصب هدوپ خواهیم بود. پیش از هر چیز، لازم است متغیرهای محیط تنظیم شوند. بدین منظور، اگر از سیستم عاملهای لینوکس مبتنی بر دبیان استفاده می کنید، فایل bashrc./~ که شامل تنظیمات محیط است را به کمک یک ویرایشگر متن مانند nano باز کرده و عبارتهای زیر را در انتهای آن اضافه کنید:

```
export HADOOP_HOME=path/to/hadoop-folder
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
```

¹⁵Hadoop native I/O



Download

Hadoop is released as source code tarballs with corresponding binary tarballs for convenience. The downloads are distributed via mirror sites and should be checked for tampering using GPG or SHA-512.

Version	Release date	Source download	\	Binary download	Release notes
3.3.1	2021 Jun 15	source (checksum signature)		binary checksum signature) binary-aarch64 (checksum signature)	Announcement
3.2.2	2021 Jan 9	source (checksum signature)		binary (checksum signature)	Announcement
2.10.1	2020 Sep 21	source (checksum signature)		binary (checksum signature)	Announcement

To verify Hadoop releases using GPG:

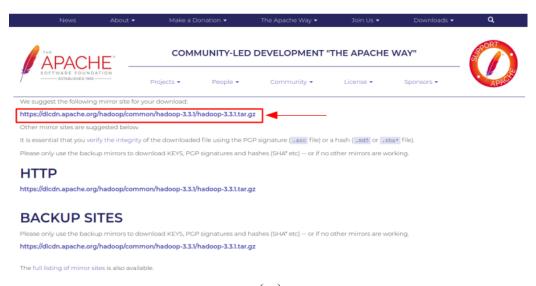
- 1. Download the release hadoop-X.Y.Z-src.tar.gz from a mirror site.
- Download the signature file hadoop-X-Y-Z-src.tar.gz.asc from Apache
 Download the Hadoop KEYS file.

- gpg –import KEYS
 gpg –verify hadoop-X.Y.Z-src.tar.gz.asc

To perform a quick check using SHA-512:

- Download the release hadoop-X.Y.Z-src.tar.gz from a mirror site.
 Download the checksum hadoop-X.Y.Z-src.tar.gz.sha512 or hadoop-X.Y.Z-src.tar.gz.mds from Apache.
- 3. shasum -a 512 hadoop-X.Y.Z-src.tar.gz





(ب)

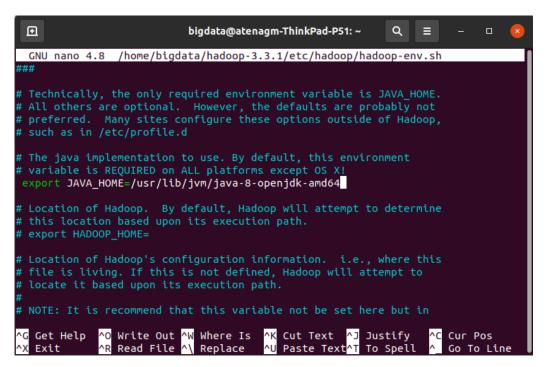
شكل ١.٢: (آ) وبسايت رسمي پروژهٔ آپاچي هدوپ. (ب) لينك پيشنهادي براي نصب هدوپ.

```
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADDOOP_HOME/lib/native
export PATH=$PATH:$HADOOP_HOME/sbin:$HADOOP_HOME/bin
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"
```

سپس، جهت اعمال تغییرات بر روی محیط، از ویرایشگر خارج شده و دستور زیر را در ترمینال اجرا کنید:

```
$ source ~/.bashrc
```

در نهایت، لازم است نسخهٔ جاوای مورد استفاده را برای دستورات هدوپ تنظیم کرد. بدین منظور، به کمک یک ویرایشگر متن، فایل HADOOP_HOME/etc/hadoop/hadoop-env.sh\$
را باز کرده، خطی که به صورت =export JAVA_HOME میباشد را از حالت کامنت خارج کرده و آدرس فایل جیدی کی را مشابه شکل ۲.۲ در مقابل آن قرار دهید.



شكل ٢.٢: شمايي از فايل اجرايي محيط هدوپ.

برای اعمال تنظیمات مشابه در ویندوز، پاورشل را باز کرده و دستورات زیر را در آن وارد کنید:

```
$ SETX JAVA_HOME "path/to/jdk" # required if you have not set
    java environment after installing java JDK
$ SETX HADOOP_HOME "path/to/hadoop-folder"
$ SETX PATH "$env:PATH;$env:JAVA_HOME/bin;$env:HADOOP_HOME/bin"
```

جهت اعمال تغییرات، پاورشل را بسته و مجدد باز کنید. جهت اطمینان از اعمال شدن تغییرات در هر یک از سیستمها، دستور زیر را اجرا کنید:

در صورتی که با خطا مواجه شدید و دستور شناخته نشد، مراحل بالا را مجدد و با دقت بررسی و تکرار کنید.

۲.۳.۲ نصب در حالت شبهتوزیع شده

پس از طی مراحل بالا، هدوپ در حالت مستقل نصب شده و قابل استفاده است. جهت نصب در حالت شبه توزیع شده، لازم است تنظیماتی صورت گیرد که در ادامه به آنها می پردازیم. این تنظیمات مستقل از سیستم عامل می باشند و تنها لازم است تغییرات لازم بر روی فایلهای ذکر شده به کمک یک ویرایشگر متن اعمال شوند. توجه داشته باشید که آدرسهای استفاده شده در این فایلها با فرض وجود کاربری به نام bigdata در سیستم لینوکس است. آدرسها را با توجه به سیستم خود و تنظیماتی که در مراحل قبل اعمال کرده اید، به طور مناسب تغییر دهید.

اولین گام در راستای نصب هدوپ در حالت شبه توزیع شده، تنظیم آدرس گره نام و آدرس فولدر موقتی که هدوپ در موتور نگاشت کاهش به کار خواهد گرفت، است. پس از ساختن فولدری بدین منظور (در اینجا فولدر tmpdata در خانه ساخته شده است)، فایل core-site.xml را باز کرده و تنظیمات زیر را در آن قرار دهید:

Listing 2.1: "core-site.xml"

همانطور که میبینید، دو خصوصیت در اینجا تعریف شده است. خصوصیت اول جهت تنظیم آدرس ذخیرهٔ موقت و خصوصیت دوم جهت تنظیم آدرس گره نام در خوشه است که در اینجا، درگاه . . . ۹ میزبان محلی قرار داده شده است.

حال، لازم است تنظیمات مربوط به اچدیافاس، موتور نگاشتکاهش و یارن صورت پذیرند. در فایل مربوط به تنظیمات اچدیافاس، لازم است محل ذخیرهٔ گرههای نام و داده و نیز، تعداد تکرارها را مشخص کنیم. تعداد تکرارها بهصورت پیشفرض عدد ۳ خواهد بود. با این حال، از آنجایی که در حال نصب هدوپ در حالت شبهتوزیعشده و بر روی یک گره هستیم، این عدد را برابر ۱ قرار خواهیم داد تا در مصرف حافظه صرف جویی شود. در تنظیمات موتور نگاشتکاهش نیز، کافیست مشخص کنیم که مدیریت منابع توسط یارن صورت خواهد گرفت و سپس، تنظیمات یارن را بهطور مقتضی ایجاد کنیم. محتویات هر سه فایل در زیر آمده است:

Listing 2.2: "hdfs-site.xml"

```
<name>dfs.data.dir</name>
  <value>/home/bigdata/dfsdata/datanode</value>
</property>
cproperty>
  <name>dfs.replication</name>
  <value>1</value>
</property>
</configuration>
```

Listing 2.3: "mapred-site.xml"

Listing 2.4: "yarn-site.xml"

```
<name>yarn.resourcemanager.hostname</name>
  <value>127.0.0.1</value>
</property>
cyarn.acl.enable</name>
  <value>0</value>
</property>
cyarn.nodemanager.env-whitelist</name>
  <value>JAVA_HOME,HADOOP_COMMON_HOME,HADOOP_HDFS_HOME,
        HADOOP_CONF_DIR,CLASSPATH_PERPEND_DISTCACHE,HADOOP_YARN_HOME,
        HADOOP_MAPRED_HOME</value>
```

در فایل تنظیمات یارن، مشاهده میکنید که یک سرویس جهت انجام فرآیند درهمآمیختن و مرتبسازی در موتور نگاشتکاهش تعریف شده است. همچنین، نام میزبان مدیر منابع و متغیرهای محیطی مورد استفاده توسط مدیر گرهها مشخص شدهاند.

در این مرحله، سیستم شما در حالت شبه توزیع شده آماده است و می توانید به بخش ۴.۲ جهت راه اندازی هدوپ رجوع کنید.

۳.۳.۲ نصب در حالت تماماً توزیع شده

برای نصب هدوپ در یک خوشه با بیش از یک گره، لازم است مراحل توضیح داده شده در بخش ۱.۳.۲ را بر روی تمامی گرهها طی کنید. سپس، با در دست داشتن آیپی مربوط به هر گره و انتخاب یکی به عنوان گره ارباب، تنظیمات مربوط به فایل هایی که در حالت شبه توزیع شده دیدیم، به همراه فایل اجرایی محیط یارن، به صورت زیر خواهند بود (توجه کنید که آدرس فایل ها را به درستی و متناسب با هر گره اصلاح کنید.):

Listing 2.5: "yarn-env.sh"

```
export JAVA_HOME=/path/to/jdk
export HADOOP_PREFIX=/path/to/hadoop-folder
export PATH=$PATH:$HADOOP_PREFIX/bin:$JAVA_HOME/bin:.
export HADOOP_COMMON_HOME=$HADOOP_PREFIX
```

```
export HADOOP_HDFS_HOME=$HADOOP_PREFIX

export YARN_HOME=$HADOOP_PREFIX

export HADOOP_CONF_DIR=$HADOOP_PREFIX/etc/hadoop

export YARN_CONF_DIR=$HADOOP_PREFIX/etc/hadoop
```

Listing 2.6: "core-site.xml"

Listing 2.7: "hdfs-site.xml"

```
<property>
<name>dfs.replication</name>
<value>2</value>
</property>
<property>
<name>dfs.permissions</name>
<value>false</value>
</property></property>
```

Listing 2.8: "yarn-site.xml"

```
<value>org.apache.hadoop.mapred.ShuffleHandler</value>
</property>
cproperty>
<name>yarn.resourcemanager.resource-tracker.address</name>
<value>Master-Hostname:8025</value>
</property>
cproperty>
<name>yarn.resourcemanager.scheduler.address</name>
<value>Master-Hostname:8030</value>
</property>
cproperty>
<name>yarn.resourcemanager.address</name>
<value>Master-Hostname:8040</value>
</property>
</property>
</property>
</property>
</property>
</property>
```

تنظیمات مربوط به موتور نگاشت کاهش مشابه آنچه در حالت شبه توزیع شده دیدیم، می باشد و در آن تنها یارن را به عنوان چارچوب مدیریت منابع معرفی می کنیم. در نهایت، فایل / HADOOP_HOME\$

tec/hadoop/slaves و آی پی مربوط به گرههای برده را در آن قرار می دهیم.

۴.۲ راهاندازی هدوپ

وقتی هدوپ را برای اولین بار راهاندازی میکنیم، لازم است گره نام را فرمت کنیم. بدین منظور، کافست دستور زیر را در ترمینال و با یاورشل اجرا کنید:

\$ hdfs namenode -format

نمونهای از نتیجهٔ اجرای دستورات بالا در شکل ۳.۲ قابل مشاهده است.

جهت آغاز سرویسهای هدوپ می توانید از دستور start-all.sh استفاده کنید. این دستور تمامی سرویسهای مرتبط را آغاز می کند. به منظور جلوگیری از آغاز فرآیندهای اضافی، می توانید تنها اچدی اف اس و یارن را به کمک دستورات زیر آغاز کنید:

```
$ start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [atenagm-ThinkPad-P51]
$ start-yarn.sh
```

```
▣
                                    bigdata@atenagm-ThinkPad-P51: ~
                                                                              Q
                                                                                   =
 igdata@atenagm-ThinkPad-P51:~$ hdfs namenode -format
WARNING: /home/bigdata/hadoop-3.3.1/logs does not exist. Creating.
2021-10-03 10:08:12,869 INFO namenode.NameNode: STARTUP_MSG:
STARTUP MSG: Starting NameNode
STARTUP_MSG: host = atenagm-ThinkPad-P51/127.0.1.1
STARTUP_MSG:
STARTUP_MSG:
                  args = [-format]
                  version = 3.3.1
STARTUP_MSG:
                  classpath = /home/blgdata/hadoop-3.3.1/etc/hadoop:/home/blgdata/had
oop-3.3.1/share/hadoop/common/llb/guava-27.0-jre.jar:/home/bigdata/hadoop-3.3.1/sh
are/hadoop/common/lib/jetty-webapp-9.4.40.v20210413.jar:/home/bigdata/hadoop-3.3.1/sh
/share/hadoop/common/lib/jcip-annotations-1.0-1.jar:/home/bigdata/hadoop-3.3.1/sha
re/hadoop/common/lib/json-smart-2.4.2.jar:/home/bigdata/hadoop-3.3.1/share/hadoop/
common/lib/jackson-annotations-2.10.5.jar:/home/bigdata/hadoop-3.3.1/share/hadoop/
2021-10-03 10:08:14,340 INFO namenode.FSImageFormatProtobuf: Image file /home/bigd
ata/tmpdata/dfs/name/current/fsimage.ckpt_000000000000000000 of size 402 bytes sa
ved in 0 seconds
2021-10-03 10:08:14,355 INFO namenode.NNStorageRetentionManager: Going to retain 1
 images with txid >= 0
2021-10-03 10:08:14,378 INFO namenode.FSNamesystem: Stopping services started for
active state
```

`ب)

2021-10-03 10:08:14,378 INFO namenode.FSNamesystem: Stopping services started for

2021-10-03 10:08:14,382 INFO namenode.FSImage: FSImageSaver clean checkpoint: txid

2021-10-03 10:08:14,382 INFO namenode.NameNode: SHUTDOWN_MSG:

SHUTDOWN_MSG: Shutting down NameNode at atenagm-ThinkPad-P51/127.0.1.1

standby state

=0 when meet shutdown.

شكل ٣.٢: چند خط آغازين و ياياني حاصل از فرمت گره نام.

```
Starting resourcemanager
Starting nodemanagers
```

توجه کنید که حتماً پیغام آغاز گره نام، گره داده، گره نام ثانوی، مدیر منابع و مدیر گره مشاهده شوند. به منظور کسب اطمینان از فعال بودن تمامی دیمنها و اجرای آنها به عنوان فرآیندهای جاوا، از دستور jps استفاده کنید. این دستور، فرآیندهای در حال اجرای جاوا را لیست می کند (شکل ۴.۲). در صورتی که هر یک از گرههای داده یا نام را در خروجی مشاهده نکردید، دستورات زیر را اجرا کنید:

```
$ rm -r /tmp/hadoop-<username>
$ hdfs namenode -format
```

در این مرحله، می توانید به رابط گرافیکی هدوب از طریق مرورگر وب دسترسی پیدا کنید. در

```
bigdata@atenagm-ThinkPad-P51:~ Q = - □ 

bigdata@atenagm-ThinkPad-P51:~$ jps

18816 NameNode

18993 DataNode

19633 NodeManager

20649 Jps

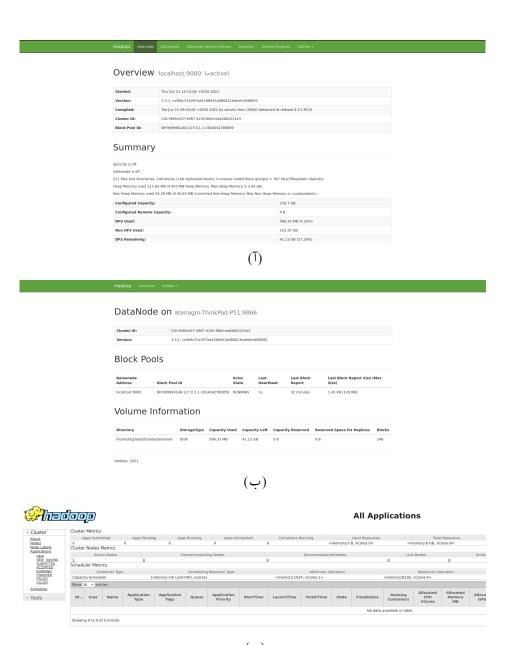
19258 SecondaryNameNode

19467 ResourceManager

bigdata@atenagm-ThinkPad-P51:~$
```

شکل ۴.۲: فرآیندهای در حال اجرای جاوا پس از آغاز اچدیافاس و یارن.

صورتی که هدوپ را در حالت تماماً توزیع شده نصب کرده باشید، این دسترسی از طریق آی پی گرهها امکان پذیر است. در حالت شبه توزیع شده، این دسترسی از طریق میزبان محلی خواهد بود. برای دسترسی به رابط گرافیکی گره نام، گرههای داده و یارن می توانید به ترتیب از درگاههای ۹۸۷۰، دسترسی به رابط گرافیکی را می توانید در شکل ۵.۲ مشاهده کنید. در انتها، برای بستن فرآیندهای در حال اجرا، می توانید در تمام دستوراتی که برای آغاز فرآیندها به کار بردید، به جای واژهٔ start از stop استفاده کنید.



(ج)

شکل ۵.۲: رابط گرافیکی گره نام $(\overline{1})$ ، گره داده (γ) و یارن (γ) .

فصل ۳

نحوه کار با اچدیافاس

برای تعامل با اچدیافاس، میتوان از خط فرمان استفاده کرد. دستورات اچدیافاس مشابه دستورات یونیکس هستند و لذا کار با آن دشوار نیست. با این حال، در شرایطی ممکن است در حال نگارش برنامه ای سطح بالا مثل پایتون باشیم که در آن نیاز به تعامل با اچدیافاس و اجرای دستورات آن داریم. در این صورت، میتوان از کتابخانه ای که برای این منظور فراهم شده است، استفاده کرد. در ادامه، پس از بررسی نحوهٔ تعامل با اچدیافاس از طریق خط فرمان، به معرفی این کتابخانه و نحوهٔ کار با آن می پردازیم. این فصل با توجه به تجربهٔ عملی و منابع [۱۱] و [۹] و مستندات کتابخانهٔ معرفی شده تنظیم شده اند.

١٠٣ نحوه تعامل از طريق محيط خط فرمان

تعامل با سیستم فایلهای توزیعشده از طریق خط فرمان با یکی از دو کلیدواژه زیر امکانپذیر است:

```
$ hadoop fs -<command> [-option <arg>]
$ hdfs dfs -<command> [-option <arg>]
```

در ادامه، جهت سادگی، از دستور دوم استفاده شده است ولی توجه کنید که هر دو دستور به طور مشابه قابل استفادهاند و تفاوتی ندارند. همان طور که پیشتر اشاره شد، دستوراتی که جهت تعامل با سیستم فایلها در هدوپ به کار می روند غالباً دستورات یونیکس هستند. به طور مثال، برای لیست کردن فایلهای ریشه (دایرکتوری روت)، می توان از دستور ۱۶ به صورت زیر استفاده کرد:

```
$ hdfs dfs -ls /
Found 2 items
```

همان طور که می بینید، در اینجا دو مورد یافت شده است. هر خط خروجی، به ترتیب شامل مجوزهای فایل/فولدر، تعداد تکرارهای فایل، کاربر فایل/فولدر، گروه آن، حجم آن به بایت، تاریخ و زمان ایجاد، و در نهایت نام فایل/فولدر است. دقت کنید که در مثال بالا، از آنجایی که هر دو مورد یافت شده فولدر هستند، تعداد تکرار با خط تیره نمایش داده شده است؛ زیرا تکرار تنها بر روی فایل ها اعمال می شود. همچنین، حجم محاسبه نشده و برابر با صفر گزارش شده است. حال، فرض کنید مجموعه ای از دادگان را در اختیار داریم. می خواهیم فولدری در اچدی اف ساخته و داده را در آن قرار دهیم. بدین منظور، به روش زیر عمل می کنیم:

اکنون، فایل مورد نظر بر روی اچدیافاس قرار گرفته است. در حالت کلی، جهت انتقال داده از حافظه داخلی به اچدیافاس و برعکس، میتوان از دستورات زیر استفاده کرد:

```
# from local to hdfs:
$ hdfs dfs -put <local-source> <hdfs-destination>
# or alternatively:
$ hdfs dfs -copyFromLocal <local-source> <hdfs-destination>
# from hdfs to local:
$ hdfs dfs -get <hdfs-source> <local-destination>
# or alternatively:
```

```
$ hdfs fsck /user/bigdata/webacc/access_log -blocks
Connecting to namenode via http://localhost:9870/fsck?ugi=
   bigdata&blocks=1&path=%2Fuser%2Fbigdata%2Fwebacc%2Faccess_log
FSCK started by bigdata (auth:SIMPLE) from /127.0.0.1 for path /
   user/bigdata/webacc/access_log at Thu Oct 21 17:15:40 IRST
   2021
Status: HEALTHY
Number of data-nodes: 1
Number of racks:
Total dirs: 0
Total symlinks:
Replicated Blocks:
Total size: 504941532 B
Total files: 1
Total blocks (validated): 4 (avg. block size 126235383 B)
Minimally replicated blocks: 4 (100.0 %)
Over-replicated blocks: 0 (0.0 %)
Under-replicated blocks: 0 (0.0 %)
Mis-replicated blocks:
                          0 (0.0 %)
Default replication factor: 1
Average block replication: 1.0
Missing blocks:
Corrupt blocks:
Missing replicas: 0 (0.0 %)
Blocks queued for replication: 0
Erasure Coded Block Groups:
```

```
Total size: 0 B

Total files: 0

Total block groups (validated): 0

Minimally erasure-coded block groups: 0

Over-erasure-coded block groups: 0

Under-erasure-coded block groups: 0

Unsatisfactory placement block groups: 0

Average block group size: 0.0

Missing block groups: 0

Corrupt block groups: 0

Blocks queued for replication: 0

FSCK ended at Thu Oct 21 17:15:40 IRST 2021 in 1 milliseconds

The filesystem under path '/user/bigdata/webacc/access_log' is HEALTHY
```

در بخش مربوط به گزارش بلوکهای تکرار شده، تعداد بلوکهایی که فایل در آن ذخیره شده است، ۴ گزارش شده است. همچنین، در مقابل آن، متوسط حجم بلوکها بر حسب بایت نمایش داده شده است.

دستورات بالا، یک نسخهٔ کپی شده از فایل/فولدر را بر روی حافظهٔ داخلی و یا اچدیافاس ایجاد میکرد. حال، فرض کنید میخواهیم فایل/فولدر کاملاً منتقل شود و از روی محل مبدأ حذف شود. در این صورت، میتوان از دستورات زیر بهره برد:

```
# move from local to hdfs
$ hdfs dfs -moveFromLocal <local-source> <hdfs-destination>
# move from hdfs to local
$ hdfs dfs -moveToLocal <hdfs-source> <local-destination>
```

همچنین، اگر بخواهیم فایل/فولدری را از روی اچدیافاس حذف کنیم، مشابه دستورات یونیکس، می توان به صورت زیر عمل کرد:

```
# remove single file
$ hdfs dfs -rm /path/to/file
# remove the whole directory
$ hdfs dfs -rm -r /path/to/folder
```

در اینجا، تعدادی از اساسی ترین دستورات را بررسی کردیم. بدیهی است که دستورات به موارد بالا محدود نمی شوند و همچنین، تسلط بر تمامی دستورات در گرو استفادهٔ چندین باره از آنهاست که ممکن است بسیاری از آنها به صورت متداول استفاده نشوند. لذا، هر زمان که نیاز به یافتن و یادآوری دستوری بود، می توانید به یکی از دو صورت زیر، لیستی از دستورات مجاز، نحوهٔ استفاده از آنها و نیز کاربرد آنها تهیه کنید:

```
# get a detailed instruction
$ hdfs dfs -help
# seek a brief list of usage
$ hdfs dfs -usage
Usage: hadoop fs [generic options]
[-appendToFile <localsrc> ... <dst>]
[-cat [-ignoreCrc] <src> ...]
[-checksum [-v] <src> ...]
[-chgrp [-R] GROUP PATH...]
[-chmod [-R] <MODE[,MODE]... | OCTALMODE > PATH...]
[-chown [-R] [OWNER][:[GROUP]] PATH...]
[-concat <target path> <src path> <src path> ...]
[-copyFromLocal [-f] [-p] [-l] [-d] [-t <thread count>] <
   localsrc> ... <dst>]
[-copyToLocal [-f] [-p] [-ignoreCrc] [-crc] <src> ... <localdst
   >1
[-count [-q] [-h] [-v] [-t [<storage type>]] [-u] [-x] [-e] [-s]
    <path> ...]
[-cp [-f] [-p | -p[topax]] [-d] <src> ... <dst>]
[-createSnapshot <snapshotDir> [<snapshotName>]]
[-deleteSnapshot <snapshotDir> <snapshotName>]
[-df [-h] [<path> ...]]
[-du [-s] [-h] [-v] [-x] <path> ...]
[-expunge [-immediate] [-fs <path>]]
[-find <path> ... <expression> ...]
[-get [-f] [-p] [-ignoreCrc] [-crc] <src> ... <localdst>]
[-getfacl [-R] <path>]
[-getfattr [-R] {-n name | -d} [-e en] <path>]
[-getmerge [-nl] [-skip-empty-file] <src> <localdst>]
```

```
[-head <file>]
[-help [cmd ...]]
[-ls [-C] [-d] [-h] [-q] [-R] [-t] [-S] [-r] [-u] [-e] [<path>
   ...11
[-mkdir [-p] <path> ...]
[-moveFromLocal [-f] [-p] [-1] [-d] <localsrc> ... <dst>]
[-moveToLocal <src> <localdst>]
[-mv <src> ... <dst>]
[-put [-f] [-p] [-1] [-d] [-t <thread count>] <localsrc> ... <
[-renameSnapshot <snapshotDir> <oldName> <newName>]
[-rm [-f] [-r|-R] [-skipTrash] [-safely] < src > ...]
[-rmdir [--ignore-fail-on-non-empty] <dir> ...]
acl_spec> <path>]]
[-setfattr {-n name [-v value] | -x name} <path>]
[-setrep [-R] [-w] <rep> <path> ...]
[-stat [format] <path> ...]
[-tail [-f] [-s <sleep interval>] <file>]
[-test -[defswrz] <path>]
[-text [-ignoreCrc] <src> ...]
[-touch [-a] [-m] [-t TIMESTAMP (yyyyMMdd:HHmmss)] [-c] <path>
   . . . ]
[-touchz <path> ...]
[-truncate [-w] <length> <path> ...]
[-usage [cmd ...]]
Generic options supported are:
-conf <configuration file>
                               specify an application
   configuration file
define a value for a given
   property
-fs <file:///|hdfs://namenode:port> specify default filesystem
   URL to use, overrides 'fs.defaultFS' property from
   configurations.
-jt <local|resourcemanager:port> specify a ResourceManager
-files <file1,...>
                                specify a comma-separated list
```

```
of files to be copied to the map reduce cluster

-libjars <jar1,...> specify a comma-separated list
  of jar files to be included in the classpath

-archives <archive1,...> specify a comma-separated list
  of archives to be unarchived on the compute machines

The general command line syntax is:

command [genericOptions] [commandOptions]
```

۲.۳ نحوه تعامل از طریق برنامهنویسی در زبان پایتون

شرکت اسپاتیفای ایک پکیج پایتون جهت ساختن یک کارخواه هدوپ و کار با اچدیاف اس و دسترسی به آن داخل برنامههای پایتون ارائه داده است. این پکیج که اسنیک بایت نام دارد، به طور مشخص برای نسخه های دوم پایتون توسعه یافت و سپس، با گسترش روزافزون نسخهٔ سوم پایتون، یک نسخه ویژهٔ پایتون ۳ نیز ایجاد شد. اسنیک بایت شامل یک کتابخانه برای ایجاد کارخواه است که می تواند به طور مستقیم با گره نام ارتباط برقرار کند. برای نصب اسنیک بایت، از دستور زیر استفاده کنید:

```
$ pip install snakebite-py3
```

حال می توانید با استفاده از کتابخانهٔ Client و ساختن یک نمونه از آن، با گره نام ارتباط برقرار کنید. برای نمونه، به برنامهٔ زیر توجه کنید:

Listing 3.1: "listdir.py"

```
from snakebite.client import Client

client = Client('localhost', 9000)
for x in client.ls(['/']):
    print(x)
```

همانطور که میبینید، برای ساخت یک کارخواه، آدرس گره نام در خوشه را به عنوان پارامترهای Client به آن دادهاییم. پارامتر اول، آدرس آی پی میزبان و پارامتر دوم، درگاهی است که گره نام

¹Spotify

²Snakebite

روی آن قرار دارد. از آنجایی که هدوپ را در حالت شبهتوزیعشده نصب کردهایم، تمامی گرهها و کارها بر روی میزبان محلی قرار دارند و همانطور که در تنظیمات هنگام نصب دیدیم، درگاهی که برای دسترسی به گره نام تعریف شد، درگاه ۹۰۰۰ است. کلاس Client پارامترهای متعددی نیز دارد که مهمترین آنها به شرح زیر میباشند:

- host: این پارامتر اجباری بوده و یک مقدار رشته ای، بیانگر نام میزبان یا آیپی آدرس گره نام، میگیرد.
- port: این پارامتر یک عدد صحیح و نمایانگر درگاه گره نام است. مقدار پیشفرض این یارامتر برابر با ۸۰۲۰ است.
- hadoop_version: این پارامتر یک عدد صحیح با مقدار پیشفرض ۹ است که نسخهٔ پروتکل هدوپ را نمایش می دهد (پروتکل هدوپ جهت مسلسل سازی داده به کار می رود).
- use_trash: این پارامتر بولی تعیین میکند که آیا هنگام انجام عملیات حذف داده از اچدیافاس از یک سطل زباله استفاده شود یا نه. در صورتیکه از سطل زباله استفاده نشود، دادهٔ حذف شده قابل برگشت نخواهد بود. مقدار این پارامتر به طور پیش فرض False است.
- effective_user: این پارامتر، کاربر مؤثر هدوپ را تعیین میکند که بهصورت پیشفرض، به کاربر فعلی اشاره میکند.

کلاس Client متدهای متنوعی دارد که هر کدام معادل با یکی از دستورات اچدیافاس که پیشتر دیدیم، عمل میکند. این متدها غالباً همنام با دستورات متناظرشان در اچدیافاس هستند. برای مثال، در قطعه کد بالا از متد ۱۶ جهت تهیهٔ لیستی از محتویات مسیر(های) داده شده (در اینجا، مسیر ریشه) بهره گرفته شده است. در حقیقت، برنامهٔ listdir.py دیکشنریهایی حاوی اطلاعات فایلها موجود در مسیر ریشه را چاپ میکند و خروجی نمونه بهصورت زیر است:

```
{'file_type': 'd', 'permission': 448, 'path': '/tmp', 'length':
    0, 'owner': 'bigdata', 'group': 'supergroup', '
    block_replication': 0, 'modification_time': 1634042832921, '
    access_time': 0, 'blocksize': 0}
{'file_type': 'd', 'permission': 493, 'path': '/user', 'length':
    0, 'owner': 'bigdata', 'group': 'supergroup', '
    block_replication': 0, 'modification_time': 1634043696607, '
    access_time': 0, 'blocksize': 0}
```

برخی از مهمترین متدهای این کلاس، به شرح زیر هستند:

- ls(paths, recurse=False, include_toplevel=False, include_children=True) این دستور لیستی از محتویات مسیرهای مشخص شده در paths تهیه میکند. سه پارامتر دیگر این، بهترتیب، تهیهٔ لیست بهصورت بازگشتی، شمول مسیر داده شده در لیست تهیه شده و شمول فرزندان در تهیهٔ لیست را تعیین میکنند.
- mkdir(paths, create_parent=False, mode=493)

 این متد جهت ایجاد دایرکتوری در مسیرهای داده شده به کار می رود. create_parent تعیین
 می کند که آیا دایرکتوری های والد را در صورت عدم وجود، بسازد یا نه. پارامتر mode نیز
 حالت ساخت را تعیین می کند.
- delete(paths, recurse=False)
 این متد معادل دستور rm در اچدیافاس است و مسیرهای مشخص شده در path را حذف
 میکند. پارامتر recurese نیز جهت حذف بازگشتی تمام محتویات به کار می رود.
- copyToLocal(paths, dst, check_crc=False)

 این متد جهت انتقال فایل از اچدیافاس به حافظهٔ محلی به کار می رود و تمامی فایل های

 مشخص شده در paths را در مسیر dst کپی می کند. پارامتر آخر جهت بررسی ارورهای
 احتمالی به کار می رود.
- df() اطلاعات سیستم فایل را بهصورت یک دیکشنری چاپ میکند.
- rename(paths, dst)

این متد مشابه دستور mv در یونیکس و اچدیافاس عمل میکند.

دو برنامهٔ زیر مثالهایی از حذف فایل و ساخت دایرکتوری می باشند:

Listing 3.2: "makedir.py"

from snakebite.client import Client

```
client = Client('localhost', 9000)
for p in client.mkdir(['test/input', 'test/output'],
    create_parent=True):
    print(p)
```

Listing 3.3: "deletedir.py"

```
from snakebite.client import Client

client = Client('localhost', 9000)
for p in client.delete(['test'], recurse=True):
    print(p)
```

در برنامهٔ makedir.py از آنجایی که پارامتر create_parent ست شده است، اگر فولدر test که والد فولدرهای مورد نظر جهت ایجاد است، از پیش وجود نداشته باشد، ابتدا آن را ایجاد کرده و سپس به ساخت فولدرهای input و test و مورتی که test و و در داخل آن می پردازد. در صورتی که test و و در داشته باشد، خروجی مشابه زیر خواهد بود:

```
{'path': '/user/bigdata/test/input', 'result': False, 'error': "
    java.io.FileNotFoundException\nParent directory doesn't exist
    : /user/bigdata/test\n\tat org.apache.hadoop.hdfs.server.
    namenode.FSDirectory.verifyParentDir(FSDirectory.java:2009)
...
org.apache.hadoop.security.UserGroupInformation.doAs(
    UserGroupInformation.java:1878)\n\tat org.apache.hadoop.ipc.
    Server$Handler.run(Server.java:2966)\n"}
{'path': '/user/bigdata/test/output', 'result': False, 'error':
    "java.io.FileNotFoundException\nParent directory doesn't
    exist: /user/bigdata/test\n\tat org.apache.hadoop.hdfs.server
    .namenode.FSDirectory.verifyParentDir(FSDirectory.java:2009)
...
org.apache.hadoop.security.UserGroupInformation.doAs(
    UserGroupInformation.java:1878)\n\tat org.apache.hadoop.ipc.
    Server$Handler.run(Server.java:2966)\n"}
```

در حالیکه اگر برنامه را چنانکه نوشته شده است، اجرا کنیم، خروجی به صورت زیر خواهد بود:
| 'path': '/user/bigdata/test/input', 'result': True}

```
{'path': '/user/bigdata/test/output', 'result': True}
```

عبارت result': True' حاکی از موفقیت در ایجاد دایرکتوریها و عدم بروز خطا می باشد.

حال، اگر بخواهیم دایرکتوری test که پیشتر ایجاد کردیم حذف کنیم، کافیست برنامهٔ deletedir.py را اجرا کنیم. نتیجهٔ اجرای برنامه به صورت زیر خواهد بود:

```
{'path': '/user/bigdata/test', 'result': True}
```

اگر در این برنامه، پارامتر recurse را برابر با False قرار میدادیم، برنامه با خطایی مشابه آنچه در زیر آمده است، مواجه می شد:

```
Traceback (most recent call last):
File "deletedir.py", line 5, in <module>
for p in client.delete(['test'], recurse=False):
File "/home/bigdata/.local/lib/python3.8/site-packages/snakebite
   /client.py", line 514, in delete
for item in self._find_items(paths, processor, include_toplevel=
   True):
File "/home/bigdata/.local/lib/python3.8/site-packages/snakebite
   /client.py", line 1237, in _find_items
entry = processor(full_path, fileinfo.fs)
File "/home/bigdata/.local/lib/python3.8/site-packages/snakebite
   /client.py", line 513, in <lambda>
processor = lambda path, node, recurse=recurse: self.
   _handle_delete(path, node, recurse)
File "/home/bigdata/.local/lib/python3.8/site-packages/snakebite
   /client.py", line 520, in _handle_delete
raise DirectoryException("rm: `%s': Is a directory" % path)
snakebite.errors.DirectoryException: rm: `/user/bigdata/test':
   Is a directory
```

فصل ۴

نگاشت کاهش در پایتون

هدوپ به گونه ای طراحی شده است که به راحتی بتوان توابع نگاشت و کاهش را به صورت برنامههایی به زبان جاوا نوشت. علاوه براین، هدوپ دارای ابزاری به نام جریان سازی هدوپ است که امکان ساخت کارهای نگاشت کاهش در هر زبان دیگری را فراهم می کند. در این بخش، نحوهٔ نگارش توابع نگاشت و کاهش در پایتون را بر روی مثالهای عملی بررسی می کنیم؛ ولی پیش از آن، لازم است مروری بر نحوهٔ عملکرد این توابع داشته باشیم.

همانطور که در فصل اول اشاره شد، تابع نگاشت، قطعههای دادهٔ ورودی را گرفته و پس از انجام پردازشهای لازم، زوجهایی از کلید_مقدار را در خروجی تولید میکند. سپس، زوجهای کلی_مقدار درهم آمیخته و مرتب شده و به تابع کاهش جهت انجام پردازشهای بعدی داده می شوند. در حقیقت، این توابع ورودیهای خود را از ورودی استاندارد خطبه خط دریافت کرده و خروجی ها را نیز خطبه خط در خروجی استاندارد می نویسند. هر خط خروجی تابع نگاشت، شامل یک زوج کلید_مقدار است که با تَب ٔ از هم جدا شده اند. تابع کاهش نیز ورودی هایی با همین فرمت را دریافت می کند و خروجی هایی به همین شکل را در خروجی استاندارد می نویسد. ابزار جریانسازی هدوپ یک کار نگاشت کاهش بر اساس توابع نوشته شده تولید کرده، آن را بر روی خوشه قرار می دهد و تا پایان فرآیند، پیشرفت آن را دنبال می کند.

برای نگارش موتور نگاشت کاهش در زبان پایتون، دو راه کلی وجود دارد:

¹Hadoop streaming

²stdin

³stdout

⁴Tab

- ١. نوشتن يک فايل قابل اجراي پايتون،
- ۲. بهرهگیری از کتابخانه هایی که امکان نوشتن توابع نگاشت و کاهش به صورت توابع مولد را فراهم میکنند.

در ادامه به بررسی هر دو روش خواهیم پرداخت. مطالب این بخش متاسب با تجربهٔ عملی، مستندات کتابخانههای معرفی شده و منابع [۹] و [۱۱] تهیه شدهاند.

۱.۴ چگونگی نوشتن توابع نگاشت و کاهش

از آنجایی که توابع نگاشت و کاهش جهت انجام پردازش بر روی دادگان نوشته می شوند، با ارائهٔ چند مثال حقیقی به تشریح این بخش خواهیم پرداخت. مثالها برگرفته از کورس آموزشی آشنایی با هدوپ و نگاشت کاهش در سایت یوداسیتی است و دادگان مورد استفاده، دادههای مربوط به گزارش سرور وبسایت یک شرکت به صورت ناشناس است. هر خط از فایل داده، شامل اطلاعات ارسال یک درخواست به سرور این وبسایت است و متشکل از اطلاعاتی از جمله، آدرس آی پی درخواست کننده، تاریخ و زمان دسترسی و نام صفحهای روی وبسایت است که به آن رجوع شده است. فرمت هر خط از داده به صورت زیر است:

ip id username [d/m/y:h:m:s zone] "mtd path qs/req" stat len

که در آن، ip آدرس آی پی کارخواه، id مشخصهٔ کارخواه، username نام کاربری کارخواه، ntd وش دسترسی، path مسیر درخواست شده، qs/req رشتهٔ پرس وجو و پروتکل درخواست، stat کد وضعیت درخواست و len اندازهٔ شیء برگشتی به بایت است. اطلاعات داخل [] نیز بیانگر تاریخ، زمان و حوزهٔ مکانی دسترسی است.

مىخواهيم با بهرهگيرى از اين فايل دادگان، به سؤالات زير پاسخ دهيم:

- ١. هر مسير روى اين وبسايت چند درخواست داشته است؟
- ۲. هر آدرس آی پی یکتا چند درخواست روی وبسایت ثبت کرده است؟

جهت پاسخگویی به هر یک از این سؤالات، لازم است خواسته ها را شناسایی کرده و فرمت خروجی مطلوب را مشخص کنیم. سپس، با تعیین فرمت ورودی و خروجی هر یک از توابع نگاشت و کاهش، به تعریف پردازشهای لازم در هر یک از آنها می پردازیم.

⁵Intro to Hadoop and MapReduce-Udacity

⁹لىنك دانلود دادگان

ابتدا با سؤال نخست آغاز میکنیم. هدف، محاسبهٔ تعداد درخواست بهازای هر مسیر روی وبسایت است. بنابراین، خروجی تابع کاهش به صورت زوجهای (مسیر، تعداد درخواست) خواهد بود. ورودی تابع نگاشت خطهای فایل داده به فرمت ذکر شده در بالا است. پس تابع نگاشت باید هر خط را پردازش کرده، مسیر را از آن استخراج کند و زوجهای به شکل (مسیر،۱) تولید کند؛ زیرا در هر خط، مسیر تنها ۱ بار آمده است. سپس، در تابع کاهش، تمام زوجهای با کلید یکسان را با یکدیگر تجمیع کرده و مجموع تکرارهای هر مسیر را محاسبه میکنیم. بدین ترتیب، تعداد کل درخواستها برای هر مسیر را در دست خواهیم داشت. بنابراین، برنامههای نگاشت و کاهش بهصورت زیر خواهند بود:

Listing 4.1: "hit mapper.py"

```
#!/usr/bin/env python3
import sys

for line in sys.stdin:
   data = line.strip().split("GET ")
   if len(data) > 1:
     filename = data[1].split()[0]
     print('{0}\t{1}'.format(filename, 1))
```

Listing 4.2: "hit_reducer.py"

```
#!/usr/bin/env python3
import sys

total = 0
prev = None

for line in sys.stdin:
   data = line.strip().split("\t")

if len(data) != 2:
   continue
```

```
k, v = data
if prev and prev != k:
    print('{0}\t{1}'.format(prev, total))
    total = 0

prev = k
    total += int(v)

if prev:
    print('{0}\t{1}'.format(prev, total))
```

همان طور که پیشتر گفته شد، توابع نگاشت و کاهش با ورودی و خروجی استاندارد کار میکنند که در پایتون به کمک کتابخانهٔ sys قابل دسترسی هستند. در فایل hit_mapper.py، بر روی خطوط ورودی حرکت کرده، هر خط را با رشتهٔ " GET" تقسیم میکنیم. اگر پس از این رشته، داده ای وجود داشته باشد، کافیست آن رشته را با فواصل تقسیم کنیم. اولین زیررشتهٔ حاصل دربردارندهٔ مسیر درخواستی است. پس آن را به همراه عدد ۱ که یک تب با نام مسیر فاصله دارد، در خروجی چاپ میکنیم.

میدانیم که خروجیهای حاصل از اجرای تابع نگاشت بر روی قطعههای مختلف داده، مرتب می شوند. بنابراین، تمامی درخواستهای مربوط به یک مسیر پشت سر هم قرار گرفتهاند. پس در فایل hit_reducer.py، پس از تفکیک هر خط از ورودی با تب و به دست آوردن نام مسیر و عدد مقابل آن، اگر نام فایل با نام فایلی که در خط پیشین خوانده ایم متفاوت باشد، بدین معنی است که دیگر درخواستی برای آن مسیر قبلی وجود نداشته است. پس کافیست نام مسیر را به همراه مجموع به دست آمده در خروجی چاپ کنیم.

در سؤال دوم خواسته شده است تا تعداد درخواستهای هر کارخواه یکتا را بیابیم. بنابراین، خروجی تابع کاهش شامل آدرس آیپی هر کارخواه و تعداد درخواستهای ارسال شده توسط او خواهد بود. این بار، جهت پردازش ورودی، باید آدرس آیپی را از هر خط استخراج کنیم و مشابه سؤال قبل عمل کنیم. لذا، فایل نگاشت به صورت زیر خواهد بود:

Listing 4.3: "hit_per_ip_mapper.py"

```
#!/usr/bin/env python3
import sys
```

```
for line in sys.stdin:
  data = line.strip().split()
  if len(data) > 1:
    ip = data[0]
    print('{0}\t{1}'.format(ip, 1))
```

از آنجایی که آدرس آیپی اولین زیررشته در هر خط میباشد، بهراحتی میتوان آن را استخراج و زوجهای (آدرس آیپی،۱) را تشکیل داد. نکتهٔ جالب آن است که نیازی به تابع کاهش جدید نیست و همان تابع قبلی قابل استفاده است.

هماکنون، کدها از لحاظ تئوری درست هستند و تنها لازم است آنها را بر روی دادگان داده شده تست کنیم و نتایج را ارائه گزارش کنیم. همواره توصیه می شود که پیش از تست موتور نگاشتکاهش بر روی خوشه و کل دادگان، بر روی کارخواه محلی و با بخش بسیار کوچکی از دادگان تست و بررسی شوند تا کدها دیباگ شوند و پس از اطمینان حاصل کردن از صحت کدها، منابع خوشه را در اختیار آنها قرار دهیم. به همین منظور، جهت بررسی صحت کدهای مربوط به سؤال نخست، ابتدا دستور زیر را در خط فرمان اجرا می کنیم تا یک بازنمایش از اجرای موتور نگاشتکاهش داشته باشیم:

```
$ head -n 50 access_log | ./hit_mapper.py | sort | ./hit_reducer
.py
```

دستور بالا، ابتدا ۵۰ خط اول فایل دادگان را در خروجی استاندارد قرار میدهد. سپس، فایل نگاشت را بر روی این نتایج اجرا کرده و پس از مرتب کردن خروجی آن، فایل کاهش را اجرا میکند. در این مرحله، میتوانید با بررسی خروجی و خطاهای احتمالی، کد را همچون یک برنامهٔ عادی پایتون دیباگ کنید. اگر با خطای Permission denied مواجه شدید، احتمالاً کدهای شما مجوز اجرا ندارند. لذا، پس از اعطای مجوز اجرا به آنها بهکمک دستور زیر، دستور بالا را مجدداً اجرا کنید.

\$ chmod a+x <filename>

حال که کد بدون نقص است، میتوانیم آن را بر روی خوشه اجرا کنیم. پس از خارج کردن فایل دادگان از حالت فشرده و قرار دادن آن بر روی اچدیافاس بهکمک دستوراتی که در فصل قبل آموختیم، جهت اجرای کار نگاشتکاهش از دستور زیر بهره میبریم:

\$ hadoop jar HADOOP_HOME/share/hadoop/tools/lib/hadoop-streaming
-*.har -files hit_mapper.py,hit_reducer.py -input webacc/

access_log -output webacc/hit_counts -mapper hit_mapper.py reducer hit_reducer.py

توجه کنید که در مستندات دستور hadoop jar آمده است که جهت اجرای یارن از دستور jar yarnlr استفاده کنید. با این حال، از آنجایی که در تنظیمات هنگام نصب، مدیریت منابع موتور نگاشتکاهش را به سمت اجرای یارن هدایت کردیم، دو دستور معادل عمل خواهند کرد. هر دوی دستورات به منظور اجرای ابزار جریانسازی هدوپ به کار می روند که در مسیر مشخص شده قرار دارند. پس از تعیین مسیر فایل جار مورد نظر، باید مسیر فایلهای مربوط به کدهای نگاشت و کاهش را مشخص کنیم. سپس، با تعریف مسیری که داده در آن قرار دارد، مشخص کردن مسیری جهت ذخیرهٔ خروجی و تعیین فایلهای نگاشت و کاهش، دستور را کامل می کنیم. همچنین، می توان با استفاده از گزینهٔ combiner-، یک تلفیق گر نیز مشخص کرد که عمدتاً همان فایل کاهش خواهد بود. به روش مشابه، می توان کدهای مربوط به سؤال دوم را نیز پس از اطمینان از صحت آنها، اجرا کرد.

اگر تمامی مراحل به صورت گفته شده طی شده باشد، با خطایی مواجه نخواهید شد. به عنوان یک قانون کلی، همیشه به خاطر داشته باشید که اگر کدی را بدون تست بر روی محیط محلی بر روی اچ دی اف اس تست کردید و با خطا مواجه شدید، اولین قدم بازگشت به کد و دیباگ آن است. همچنین، همیشه مطمئن شوید که کدها اجازهٔ اجرا دارند. دستهٔ دیگری از مشکلات می توانند ناشی از تنظیمات زمان نصب، از جمله آدرس گرهها بر روی خوشه باشند. در متن خطاهایی از این جنس، صراحتاً ذکر می شود که آدرس اجراکنندهٔ کد با آدرس تنظیم شده مطابقت ندارد و غالباً از جنس صراحتاً ذکر می شود که آدرس اجراکنندهٔ کد با آدرس تنظیم شده مطابقت ندارد و غالباً از جنس در تنظیمات رفع خواهد شد. اگر تناقضی در تنظیمات وجود نداشت، مجدداً گره نام را فرمت کنید (در فصلهای پیشین به آن پرداخته شده است).

۲.۴ بهره گیری از کتابخانهها

کتابخانه هایی جهت نگارش موتور نگاشت کاهش در پایتون و بدون نیاز به اجرای مجزای آن توسط جار، توسعه یافته اند که از جملهٔ آن ها می توان به هدوپای V ، پای دوپ و دیسکو و ام آرجاب اشاره کرد. با این حال، پروژه ای که به صورت فعال به روز رسانی می شود و کار با آن ساده می باشد،

⁷Hadoopy

⁸Pydoop

⁹Disco

¹⁰mrjob

امآرجاب است که توسط شرکت یلپ ۱۱ توسعه یافته است. به همین دلیل، این کتابخانه از محبوبیت بالایی برخوردار است و در اینجا نیز استفاده از آن را بررسی خواهیم کرد.

این کتابخانه به برنامهنویس این امکان را میدهد تا کارهای نگاشتکاهش خود را بر روی سیستم محلی تست کند و یا بر روی خوشه آن را اجرا کند. با این حال، از لحاظ عملکردی، در مقایسه با حالت پیشین، سرعت پایینتری دارد و در صورتیکه زمان اجرا از اهمیت بالایی برخوردار باشد، استفاده از آن توصیه نمیشود. در امآرجاب، نیازی به نوشتن فایلهای جداگانه برای کارهای نگاشت و کاهش نیست؛ بلکه کافیست یک کلاس شامل متدهایی مولد برای انجام کارهای نگاشت و کاهش تعریف کنیم. کد زیر پاسخی برای سؤال نخست به کمک این کتابخانه است:

Listing 4.4: "hit_count_mrjob.py

```
class HitCount(MRJob):
    def mapper(self, _, line):
        data = line.strip().split("GET ")
        if len(data) > 1:
            filename = data[1].split()[0]
            yield(filename, 1)

def reducer(self, filename, counts):
        yield(filename, sum(counts))
if __name__ == '__main__':
    HitCount.run()
```

به منظور نوشتن موتور نگاشت کاهش به کمک این کتابخانه، کافیست کلاسی بنویسیم که از کلاس MRJob ارث بری میکند. در اینجا خبری از حلقه نیست، چراکه توابع به صورت مولدهایی به ازای هر خط نگارش می شوند و متد run خود، صدا زدن توابع را مدیریت میکند. توابع نگاشت، کاهش و تلفیق گر با متدهایی با نامهای reducer ، mapper و combiner هستند که هر کدام از آنها دو پارامتر ورودی دارند. این دو پارامتر همان زیررشته هایی هستند که با تب جدا شده اند. با این حال، ورودی تابع نگاشت غالباً یک خط بدون تب است که در پارامتر دوم قرار می گیرد.

¹¹Yelp

برنامهٔ نوشته شده به کمک این کتابخانه می تواند در حالت های گوناگونی اجرا شود:

- r inline
 این گزینه جهت اجرای کد به صورت یک فرآیند پایتون بر روی سیستم محلی به کار می رود.
- r local
 با استفاده از این گزینه، میتوان برنامه را بهصورت چند زیرفرآیند پایتون بر روی سیستم
 محلی اجرا کرد و تا حدی اجرا بر روی اچدیافاس را شبیهسازی کرد.
- -r hadoop

این گزینه برای اجرای برنامه روی هدوپ و اچدیافاس استفاده میشود.

بنابراین، جهت اجرای برنامهای که در بالا نوشتیم بر بستر هدوپ، میتوان از دستور زیر کمک گرفت:

\$ python hit_count_mrjob.py -r hadoop hdfs:///user/bigdata/
webacc/access_log

فصل ۵

جمع بندی و نتیجه گیری

در این گزارش به بررسی مفاهیم اولیهٔ هدوپ و اجزاء آن، از جمله اچدیافاس، موتور نگاشتکاهش و یارن پرداختیم. همچنین، تاریخچهای از آغاز و توسعهٔ هدوپ بههمراه توضیح مختصری از پروژههای مرتبط را ارائه کردیم. دیدیم که هدوپ چارچوبی متنباز با دسترسپذیری بالا است که با قرارگیری در کنار دیگر نرمافزارهای اکوسیستم هدوپ، امکانات گستردهای را جهت پردازش و تحلیل مهداده ها در اختیار قرار می دهد.

سپس، به نصب و کار با هدوپ پرداخته شد. پس از بررسی حالتهای نصب، توضیح مبسوطی جهت نصب در حالت مستقل و شبه توزیع شده بر روی سیستم های مبتنی بر یونیکس، به ویژه لینوکس/دبیان، ارائه شد. راهنمای نصب بر روی سیستم عامل ویندوز و نیز نصب در حالت تماماً توزیع شده تشریح شده است. با ارائهٔ راهنما جهت راهاندازی اچدی اف اس و یارن، به بررسی دستورات جهت تعامل با اچدی اف اس از طریق خط فرمان و یا داخل برنامه های پایتون پرداختیم. در نهایت، با بررسی مثالی عملی، نگارش توابع نگاشت و کاهش در زبان پایتون را مورد مطالعه قرار دادیم.

هدف این کتابچه، آشنایی اولیه با مفاهیم و مبانی کار با هدوپ بود و همچنان مباحث زیادی از دنیای گستردهٔ هدوپ ناگفته مانده است. در ادامه، منابعی را برای افراد علاقهمند معرفی میکنیم تا با مطالعهٔ آنها، بتوانند در این دنیای گسترده گامهای مؤثرتری بردارند.

• یکی از منابع اصلی این گردایه، کتاب هدوپ از تام وایت بود [۱۱]. تام وایت یکی از توسعه دهندگان پروژهٔ هدوپ است و توضیحات دقیقی از نحوهٔ کار با اچدی اف اس، نگاشت کاهش و یارن ارائه کرده است. همچنین، به بررسی برخی پروژه های مرتبط نیز پرداخته است. با وجود اینکه این کتاب برای نسخهٔ دوم هدوپ نگارش شده است، همچنان منبع جامعی برای افراد علاقه مند است.

- کتاب Hadoop in Practice نوشتهٔ الکس هولمز از نشر Manning از جمله کتابهایی است که به افراد علاقهمند جهت یادگیری عملی تحلیل دادهها و مهدادهها بهکمک هدوپ معرفی می شود. این کتاب با ارائهٔ مثالهای متعدد یکی از کتابهای کمکی خوب به شمار می رود.
- برای آن دسته از افرادی که میخواهند بیشترین بهره را از آخرین نسخهٔ هدوپ ببرند، توصیه می شود نگاهی به کتاب Big Data Analytics with Hadoop 3.0 نوشتهٔ سریدار آلا از نشر Packt داشته باشند. این کتاب با تکیه بر آخرین تغییرات صورت گرفته در پروژهٔ هدوپ، به تشریح تحلیل داده به کمک هدوپ و ابزارهایی نظیر اسپارک، پایتون و آر می پردازد.

كتابنامه

- [1] https://cwiki.apache.org/confluence/display/HADOOP2/Home.
- [2] Apache hadoop official website. https://hadoop.apache.org/.
- [3] What is hadoop? https://aws.amazon.com/emr/details/hadoop/what-is-hadoop/.
- [4] https://www.geeksforgeeks.org/hadoop-version-3-0-whats-new/, 2020.
- [5] Apache hadoop architecture explained (with diagrams). https://phoenixnap.com/kb/apache-hadoop-architecture-explained, 2020.
- [6] R. Buyya, R. N. Calheiros, and A. V. Dastjerdi. *Big data: principles and paradigms*, chapter 7. Morgan Kaufmann, 2016.
- [7] W. L. Bounsi. How to install hadoop on a real cluster (fully distributed mode). https://medium.com/@wilcoln/how-to-install-hadoop-on-a-re al-cluster-fully-distributed-mode-7c3bc3fa7d7e, 2019.
- [8] A. Mumtaz. A beginner's guide to hadoop's fundamentals. https://towardsdatascience.com/a-beginners-guide-to-hadoop-s-fundamentals-8e9b19744e30, 2021.
- [9] Z. Radtka and D. Miner. *Hadoop with Python*. O'Reilly Media, 2015.

- [10] S. Singhal. Hadoop: How to install in 5 steps in windows 10. https://medium.com/analytics-vidhya/hadoop-how-to-install-in-5-steps-in-windows-10-61b0e67342f8, 2021.
- [11] T. White. Hadoop: The Definitive Guide. O'Reilly Media, Inc., 2015.